Normalidade Contextual em APIs: Caracterização e Classificação de Regimes de Comportamento a partir de Access Logs

Diego Paz Casagrande
Universidade de Brasília

Resumo

O comportamento operacional de uma API não é necessariamente estacionário: volume de requisições, latência e taxa de erro variam legitimamente em função de horário, calendário de negócio, processamento em lote e janelas de manutenção, comuns em ambientes que integram sistemas legados e modernos. Mecanismos convencionais de monitoramento, baseados em parâmetros fixos e em um único perfil de normalidade, têm dificuldade em distinguir essa variação legítima de um desvio real de comportamento, gerando falsos positivos e exigindo parametrização manual por especialista para cada API. Este trabalho investiga se atributos estatísticos derivados exclusivamente de API Access Logs (AALs), o registro consolidado gerado pelo gateway de API, distinto de logs de execução ou de aplicação, são suficientes para caracterizar múltiplos regimes de comportamento normal e classificar estados comportamentais associados à degradação, sem depender de traces, logs internos ou validação por especialista de domínio. Adotando o modelo CRISP-DM, com ênfase no Entendimento do Negócio e do Dado, o método combina descoberta não supervisionada de regimes com classificação supervisionada dos estados de Normalidade. Os resultados esperados incluem a identificação empírica dos regimes de comportamento característicos das APIs analisadas, o desempenho comparativo dos classificadores frente a baselines estatísticos simples, e a identificação dos atributos mais relevantes para a discriminação dos estados.

Keywords

Mineração de Dados; API Access Log; Caracterização Comportamental; CRISP-DM; Regimes Operacionais.

1 INTRODUÇÃO

A arquitetura dos sistemas modernos consolidou o uso de APIs (Application Programming Interfaces) como mecanismo fundamental de integração e comunicação em sistemas distribuídos. Nos paradigmas de desenvolvimento de software contemporâneo, a geração de valor econômico e operacional depende da capacidade de compartilhamento padronizado de dados e funcionalidades entre serviços heterogêneos. Nesse escopo, as APIs medeiam desde requisições externas originadas de clientes web até transações internas executadas entre sistemas legados e modernos operando de forma integrada em infraestruturas corporativas de larga escala. Garantir a compreensão do comportamento operacional dessas APIs constitui, portanto, um requisito relevante para a sustentação de ambientes corporativos que dependem de volumoso número de integrações.

1.1 Contexto

Em ambientes corporativos, requisições processadas por gateways de API geram registros transacionais contendo informações como instante da execução, recurso acessado, código de resposta e tempo de processamento. Neste estudo, esses registros são denominados API Access Logs (AALs): o registro consolidado gerado pelo gateway para cada requisição processada, contendo metadados da chamada, distinto do execution log e do log de aplicação, que registram o detalhamento interno do processamento da execução do serviço de destino. Essa delimitação é relevante porque os AALs tendem a estar disponíveis de forma padronizada para um conjunto amplo de APIs, sem exigir instrumentação específica no código das aplicações.

O comportamento operacional de uma API não é necessariamente estacionário. O volume de requisições, a latência e a proporção de códigos de erro podem variar em função do horário, do dia da semana, de calendários de negócio, de processamentos em lote e de janelas de manutenção, comuns em ambientes com sistemas mainframe. Consequentemente, diferentes configurações dos atributos observados podem representar condições normais dentro de contextos operacionais distintos, o que dificulta o emprego exclusivo de parâmetros fixos: uma elevação da latência pode representar uma degradação, mas também pode ser consequência de um aumento esperado do volume; a redução abrupta do tráfego pode indicar indisponibilidade ou, igualmente, o encerramento do período de atendimento ou a suspensão programada de um processo de negócio.

1.2 Problema

APIs que sustentam sistemas distribuídos de grande porte nem sempre falham de forma abrupta. As abordagens convencionais de monitoramento comparam métricas correntes com parâmetros previamente definidos, adequadas para violações explícitas, mas limitadas quando o comportamento esperado varia segundo o contexto operacional, dificultando a distinção entre uma variação legítima de regime e um comportamento que não se ajusta a nenhum regime normal conhecido.

Do ponto de vista científico, o problema consiste em verificar se atributos derivados exclusivamente de AALs, agregados em janelas temporais, apresentam capacidade informativa suficiente para: (1) caracterizar múltiplos regimes de comportamento operacional; (2) diferenciar variações esperadas de alterações persistentes; e (3) identificar estados associados à degradação.

O problema de mineração de dados é formulado como uma tarefa não supervisionada de descoberta de regimes recorrentes de comportamento, complementada por uma tarefa de classificação, supervisionada quando houver rótulo histórico disponível, que atribui cada janela observada a um estado de Normalidade Contextual (multi-regime), a uma variação transitória (Transição) ou a um estado de Degradação Residual.

1.3 Motivação

As unidades de operação de TI atuam, em grande parte, de forma reativa a partir de alertas de monitoramento baseados em limites

previamente estabelecidos (ZHANG et al., 2025). Sua dependência de um perfil único de normalidade tende a gerar elevadas taxas de falsos positivos justamente nos períodos em que a variação de comportamento é esperada e legítima, reduzindo a confiança das equipes de suporte nos alertas gerados.

No Banco do Brasil, uma instituição financeira de grande porte, tem-se a necessidade de formalização de acordos de nível de serviço (SLA) e de especialistas de domínios para a parametrização com limiares fixos para sustentação do ambiente, sendo necessária uma avaliação para cada API para a definição dos parâmetros de normalidade. Embora esses mecanismos de monitoramento sejam essenciais para a operação, sua abordagem baseia-se predominantemente no estado instantâneo do sistema, gerando altas taxas de falsos positivos e identificando desvios operacionais apenas quando o impacto ao usuário final já se materializou.

Hipotetiza-se que a caracterização sistemática dos regimes de comportamento normal de uma API, obtida a partir da análise estatística de seu Access Log histórico, pode ser aplicada de forma escalável a um grande conjunto de APIs, reduzindo a dependência de regras específicas definidas manualmente para cada serviço e contribuindo, de forma indireta, para a redução de alertas ruidosos. A abordagem investigada neste trabalho busca reduzir essa dependência de parametrização manual por especialista, ao identificar os regimes de comportamento a partir dos próprios dados históricos.

1.4 Objetivo geral

Desenvolver e avaliar, com base no modelo CRISP-DM, uma abordagem de mineração de dados capaz de caracterizar estatisticamente o comportamento transacional de APIs a partir de seus logs de execução, de modo a classificar seus estados comportamentais em Normalidade Contextual, Transição e Degradação Residual.

1.5 Objetivos específicos

- Caracterizar estatisticamente o comportamento transacional das APIs, por meio de atributos agregados em janelas temporais, estabelecendo baselines de comportamento normal.
- Identificar padrões e possíveis estados comportamentais a partir da caracterização estatística realizada.
- Desenvolver e comparar modelos de classificação capazes de distinguir os estados comportamentais identificados.
- Identificar quais características (atributos) apresentam maior relevância para a classificação dos estados.

1.6 Questões de pesquisa

- RQ1. Os logs de execução (AALs) de uma API contêm informações estatísticas suficientes, quando agregadas em janelas temporais, para caracterizar regimes operacionais e diferenciar estados comportamentais distintos (Normalidade Contextual, Transição e Degradação Residual)?
- RQ2. É possível desenvolver modelos capazes de classificar, com desempenho satisfatório, os estados comportamentais identificados a partir dos atributos estatísticos extraídos dos AALS?
- RQ3. Quais características extraídas dos AALs apresentam maior relevância para a classificação dos estados?

1.7 Organização do artigo

O restante deste artigo está organizado da seguinte forma. A Seção 2 apresenta os trabalhos correlatos, discutindo mineração de logs para caracterização de comportamento, categorização do comportamento normal, modelagem comportamental de APIs, tratamento de degradações residuais e limitações de generalização, encerrando com a sintese comparativa e a lacuna de pesquisa. A Seção 3 descreve a metodologia CRISP-DM adotada. A Seção 4 apresenta a proposta e o desenho experimental. A Seção 5 apresenta os resultados, e a Seção 6 traz as considerações finais.

2 TRABALHOS CORRELATOS

2.1 Análise e mineração de logs

A utilização de logs como fonte para identificação de comportamentos anormais foi explorada por Du et al. (2017) no DeepLog. O método emprega redes LSTM para aprender sequências normais de eventos e sinalizar desvios em relação ao padrão esperado. O trabalho também considera atualização incremental do modelo para incorporar novos padrões. Apesar de sua relevância, seu objeto é constituído por eventos extraídos de logs de sistema e sua unidade analítica é predominantemente sequencial, diferentemente dos AALs agregados em janelas temporais considerados neste estudo.

Meng et al. (2019) propuseram o LogAnomaly, que utiliza informação semântica dos templates de log e combina a identificação de anomalias sequenciais e quantitativas. A abordagem é relevante por demonstrar que propriedades de frequência complementam a análise da ordem dos eventos. Entretanto, o método foi concebido para logs não estruturados e não tem como objetivo separar múltiplos regimes normais definidos por contexto temporal.

2.2 Categorização e classificação do comportamento normal

Siffer et al. (2017) apresentaram o DSPOT (Streaming Peaks-Over-Threshold), método baseado em Teoria de Valores Extremos (Extreme Value Theory, EVT) para ajuste automático de limiares em fluxos de dados. Diferentemente de abordagens que assumem uma distribuição estatística fixa (por exemplo, gaussiana) para definir o limite entre comportamento normal e anômalo, os autores partem da observação de que o interesse está justamente na cauda da distribuição, nos valores extremos, raros por definição, e que a EVT oferece um resultado assintótico sobre o comportamento dessa cauda que independe da distribuição original dos dados. A contribuição central do trabalho é o algoritmo SPOT, capaz de calibrar um limiar estatisticamente fundamentado a partir de um fluxo de dados sem qualquer conhecimento prévio de sua distribuição, e sua extensão DSPOT, que incorpora uma janela de observação local para lidar com séries não estacionárias, ou seja, capazes de adaptar o próprio limiar quando o nível médio ou a variabilidade da série mudam ao longo do tempo. Os autores avaliam o método tanto em dados sintéticos quanto em séries reais (incluindo tráfego de rede), reportando controle eficaz da taxa de falsos positivos mesmo sob mudança de regime na série.

Essa capacidade de adaptação é particularmente relevante para o problema investigado neste artigo: um limiar fixo definido para uma

API em regime de tráfego comercial tende a gerar falso positivo sistemático quando aplicado, sem ajuste, a um regime de baixo volume noturno ou a uma janela de processamento em lote exatamente o tipo de variação legítima que este trabalho busca caracterizar. A adaptação local do DSPOT, contudo, opera sobre uma única série de valores extremos ao longo do tempo, e não constrói uma categorização explícita de diferentes regimes coexistentes: 0 método ajusta continuamente um limiar, mas não identifica ou nomeia os contextos que fazem esse limiar variar. A contribuição é relevante, portanto, por substituir limites estáticos por limiares adaptados à distribuição observada, mas essa adaptação não produz, por si só, uma categorização semântica de regimes operacionais.

Audibert et al. (2020) propuseram o USAD, método não supervisionado baseado em autoencoders para séries temporais multivariadas. O trabalho avalia o método em cinco conjuntos públicos e em dados proprietários, considerando desempenho, estabilidade e tempo de treinamento. Embora seja aplicável a métricas operacionais multivariadas, o objetivo permanece centrado na atribuição de escores de anomalia, e não na interpretação de múltiplos regimes normais de APIs.

WANG et al. (2025), em Cross-System Categorization of Abnormal Traces via Meta-Learning, discutem a dificuldade de generalizar um modelo entre sistemas distintos. Essa limitação é relevante porque diferentes APIs, mesmo em um mesmo ecossistema corporativo, podem ter regimes de sazonalidade e regras de negócio distintos, tratada neste artigo como análise exploratória.

Esses trabalhos fundamentam o tratamento dos atributos agregados dos AALs como séries temporais multivariadas, mas também evidenciam uma diferença: o presente estudo procura separar dois problemas que frequentemente aparecem combinados na literatura, a descoberta de regimes e a caracterização de degradação, tratando esta última como consequência residual da primeira, e não como alvo direto e independente de detecção.

2.3 Modelagem comportamental de APIs

Zhang et al. (2022) no DeepTraLog, que representa conjuntamente traces e logs por meio de grafos e utiliza aprendizado profundo para detectar anomalias em microsserviços. A abordagem explora relações estruturais indisponíveis em um AAL isolado, como a hierarquia de chamadas e os eventos internos de cada serviço. Somashekar et al. (2024) propuseram o GAMMA, que combina informações operacionais para localização de múltiplos gargalos em aplicações de microsserviços. A proposta reforça o potencial da integração de diversas modalidades, mas depende de uma riqueza de observações superior à disponibilizada por um AAL.

Esses estudos apresentam desempenho e capacidade diagnóstica superiores em determinados cenários, mas pressupõem disponibilidade de traces, logs internos ou métricas de infraestrutura. O presente projeto investiga uma questão complementar: qual é a capacidade de caracterização comportamental obtida quando se utiliza exclusivamente o registro padronizado produzido pelo gateway (o AAL)?

2.4 Síntese da literatura

A literatura correlata revisada nas seções anteriores pode ser organizada em três grupos, segundo o objeto de dados e o tipo de contribuição oferecida. O primeiro grupo reúne trabalhos de mineração de log de sistema orientados à detecção sequencial de anomalia, como (DU et al., 2017), no DeepLog, publicado no ACM CCS, e (MENG et al., 2019), no LogAnomaly, publicado no IJCAI. Ambos demonstram que um log de execução carrega informação suficiente para caracterizar comportamento, premissa conceitual da qual este artigo parte, mas operam sobre sequências de eventos de log de aplicação, granularidade distinta do Access Log agregado por janela investigado aqui, e nenhum dos dois trata da coexistência de múltiplos regimes de comportamento normal.

O segundo grupo reúne trabalhos voltados à detecção de anomalia em séries temporais multivariadas, como (SIFFER et al., 2017), no DSPOT, e (AUDIBERT et al., 2020), no USAD. Esses trabalhos são relevantes por tratar o problema de forma agnóstica ao tipo de sistema, operando diretamente sobre métricas numéricas, mas permanecem centrados na atribuição de escore ou limiar de anomalia sobre um único perfil de referência, sem propor uma etapa explícita de categorização de regimes.

O terceiro grupo reúne trabalhos de modelagem comportamental de microsserviços a partir de fontes multimodais, como (ZHANG et al., 2022), no DeepTraLog, e (SOMASHEKAR et al., 2024), no GAMMA. Esses trabalhos alcançam capacidade diagnóstica superior em cenários específicos, mas dependem de dados de trace, log interno de aplicação ou métricas de infraestrutura, fontes que extrapolam o Access Log isolado, objeto exclusivo deste artigo. Complementarmente, (WANG et al., 2025) discute a dificuldade de generalizar modelos de categorização de comportamento entre sistemas distintos, limitação relevante quando se considera que diferentes APIs de um mesmo ecossistema corporativo podem apresentar regimes de sazonalidade e regras de negócio próprios.

Em conjunto, esses três grupos evidenciam um padrão comum: a literatura correlata trata, de forma predominante, o comportamento de um sistema como decorrente de um único perfil de normalidade, a partir do qual desvios são detectados ou pontuados, nenhum dos trabalhos revisados investiga explicitamente a coexistência de múltiplos regimes normais legítimos, tampouco propõe tratar os estados de Transição e Degradação Residual como consequência residual dessa caracterização multi-regime, e nenhum deles investiga a suficiência do Access Log de API, isoladamente, para essa finalidade.

2.5 Lacuna

Embora os estudos publicados investiguem mineração de log de execução e detecção de anomalia em séries multivariadas, nenhum investiga a caracterização de múltiplos regimes de comportamento normal de uma API, decorrentes de sazonalidade, janelas de manutenção ou regra de negócio, a partir exclusivamente do AAL, tratando os estados de Transição e Degradação Residual como desvio residual em vez de alvo direto de detecção.

3 METODOLOGIA

3.1 CRISP-DM

Este trabalho adota o modelo de referência CRISP-DM (Cross-Industry Standard Process for Data Mining), amplamente adotado na literatura científica e na indústria para estruturar projetos de mineração de dados. A escolha desse framework justifica-se por sua

natureza iterativa e por seu foco na descoberta de conhecimento, permitindo alinhar a exploração dos AAL transacionais às dinâmicas operacionais de sistemas produtivos corporativos. A seguir, detalha-se a aplicação de cada uma das seis fases do modelo ao problema de caracterização comportamental em APIs.

3.2 Entendimento do negócio

No contexto de APIs corporativas que interagem com sistemas complexos, como arquiteturas em nuvem integradas a mainframes legados, o volume de requisições e a latência flutuam em virtude de processos de negócio, e não apenas de falhas. Neste trabalho, o problema é caracterizar os regimes de comportamento operacional de APIs utilizando informações disponíveis em seus próprios registros de execução (AAL), de modo que o "esperado"seja definido em função do contexto, e não por um perfil estático único.

Esta será a fase central do projeto. O objetivo de negócio é apoiar equipes responsáveis pela operação de APIs na priorização de análises, a partir da identificação e categorização dos regimes de comportamento normal de cada API. Como consequência direta dessa caracterização, torna-se possível qualificar com mais precisão os desvios observados, tratando a Transição e a Degradação Residual como resíduo em relação aos regimes normais identificados, e não como evento a ser antecipado.

A decisão apoiada pelo modelo será: quais APIs ou endpoints devem receber análise prioritária devido à presença de comportamento que não se ajusta a nenhum regime normal identificado para aquela API?

Os objetivos de mineração decorrentes são: (1) descrever estatisticamente o comportamento das APIs; (2) descobrir regimes recorrentes; (3) associar regimes a contextos temporais identificados empiricamente nos dados; (4) identificar janelas compatíveis com Normalidade Contextual, Transição ou Degradação Residual.

Os critérios de sucesso são divididos em técnicos compreendendo desempenho superior a baselines, estabilidade temporal e capacidade de discriminar estados; e científicos como reprodutibilidade, ausência de vazamento temporal e análise das limitações da fonte de dados. Os calendários relevantes e os eventos esperados, janelas de manutenção e processamento em lote não dependem de validação por especialista de domínio, são identificados diretamente na fase de Entendimento dos Dados, a partir de padrões estatísticos recorrentes como quedas ou picos sistemáticos em horários fixos, o que torna o método autocontido e executável com os dados disponíveis.

3.3 Entendimento dos dados

Os dados são constituídos por AALs individualizados, com atributos candidatos: data/hora da requisição, API e endpoint, método HTTP, código de resposta, latência, categoria de erro, gateway, aplicação consumidora e provedora. A análise estatística descritiva é conduzida em Python (pandas, NumPy, SciPy, statsmodels, scikit-learn, Matplotlib, Seaborn), compreendendo: quantidade de registros por período; valores ausentes e duplicidades; distribuição de latência e percentis (p50, p90, p95, p99); proporção de respostas por família HTTP; frequência por API e endpoint; assimetria e dispersão; autocorrelação e sazonalidade; comportamento por hora, dia da semana e calendário. $\vec{E}$ produzido um relatório de qualidade de dados com disponibilidade temporal, completude, consistência, granularidade e riscos de viés, é nesta etapa, e não por validação externa, que se confirma empiricamente a existência dos regimes hipotetizados na Introdução.

3.4 Preparação dos dados e engenharia de atributos

Os registros são ordenados temporalmente, deduplicados e submetidos a regras documentadas de validade; identificadores técnicos são anonimizados quando necessário, sem uso de payloads ou dados pessoais. Os eventos são agregados em janelas de 1, 5 e 15 minutos, calculando: volume total; taxa de sucesso e taxas por família HTTP ($2xx/4xx/5xx$) média, mediana, desvio-padrão e percentis de latência; número de consumidores distintos; variação absoluta/relativa em relação à janela anterior e ao mesmo horário de períodos anteriores; médias e desvios móveis; inclinação das métricas em sequências de janelas; e duração/persistência do desvio. A normalização é ajustada somente com dados de treinamento, e valores futuros não participam do cálculo dos atributos da janela corrente, regra que evita vazamento temporal mesmo numa tarefa de classificação retrospectiva.

3.5 Definição operacional dos estados

Os regimes normais são descobertos de modo não supervisionado; atribuições semânticas são realizadas somente após análise das características de cada agrupamento frente aos padrões de calendário. Os estados de Normalidade Contextual, Transição e Degradação Residual são definidos por combinação de: distância em relação ao regime esperado; direção operacionalmente desfavorável da mudança; e persistência por número mínimo de janelas.

3.6 Modelagem

- Experimento 1 Descoberta de regimes: comparação entre métodos de agrupamento particional (k-means), hierárquico e baseado em densidade (DBSCAN), avaliando se as janelas formam grupos estáveis e interpretáveis. DBSCAN é tratado como técnica de descoberta/agrupamento, não como detector de anomalia por definição.
- Experimento 2 Classificação dos estados: comparação entre regressão logística, árvore de decisão, Random Forest e gradient boosting (XGBoost) para atribuir cada janela à Normalidade Contextual, Transição ou Degradação Residual.
- Experimento 3 Importância das características: Análise de importância de atributos (feature importance/SHAP) para identificar quais variáveis mais contribuem para a classificação dos estados.

3.7 Avaliação

A avaliação é cronológica, com janelas expansivas ou deslizantes, mantendo sempre o treinamento anterior ao teste. Para agrupamento: Silhouette, Davies-Bouldin, Calinski-Harabasz e estabilidade entre períodos. Para classificação: Precision, Recall, Fl-score por classe, F1 macro, PR-AUC e matriz de confusão. Intervalos de eventos correlacionados são avaliados como um único episódio operacional, evitando contar sucessivas janelas do mesmo estado

de Degradação Residual como acertos independentes. São também analisados desempenho por API.

4 PROPOSTA E DESENHO EXPERIMENTAL

Esta seção detalha o desenho experimental delineado para materializar as fases de modelagem e avaliação previstas na metodologia CRISP-DM. O experimento é estruturado de forma progressiva, garantindo a viabilidade prática da caracterização de regimes e da classificação estrita de estados comportamentais.

4.1 Arquitetura conceitual

O fluxo analítico conceitual segue uma esteira de processamento sequencial: Ingestão dos API Access Logs (AALs) brutos → Carga e validação de qualidade → Agregação temporal em janelas discretas → Engenharia de atributos (contexto e variação) → Descoberta não-supervisionada de regimes → Classificação do estado comportamental corrente.

Cada etapa corresponde a um módulo lógico isolado. Essa arquitetura permite validar a viabilidade e a consistência dos dados em cada fase antes de avançar para a modelagem complexa, garantindo que o fluxo não seja construído sobre premissas estatísticas inválidas. A arquitetura não pressupõe acesso a payloads, traces distribuídos ou logs internos das aplicações, operando exclusivamente sobre os metadados gerados pelo gateway. A unidade elementar de observação na modelagem é a janela temporal agregada, avaliada em granularidades de 1, 5 e 15 minutos.

4.2 Caracterização da base e contexto dos dados

A pesquisa utilizará uma amostra real e anonimizada de dados corporativos de produção do Banco do Brasil. Essa escolha garante que a modelagem incida sobre complexidades inerentes a ecossistemas corporativos de larga escala, contemplando a integração com sistemas de mainframe, sazonalidades de negócio autênticas e rotinas reais de processamento em lote (batch). O uso dessa amostra está condicionado aos processos internos de governança de dados da instituição e às exigências da Lei Geral de Proteção de Dados (LGPD), com identificadores técnicos anonimizados e sem utilização de payloads ou dados pessoais. Em contrapartida, essa origem impõe uma limitação de reprodutibilidade externa, já que a base utilizada não pode ser publicamente compartilhada.

A etapa de caracterização inicial da base reportará estatísticas descritivas essenciais: quantidade absoluta de registros, período temporal coberto, granularidade, número de APIs e endpoints distintos, além da completude dos campos.

4.3 Engenharia de atributos

O vetor de características de cada janela temporal é construído para descrever o comportamento operacional instantâneo e sua evolução recente. Os atributos são divididos nas seguintes dimensões:

- Volume e Resposta: Taxa de requisições, taxa de sucesso e proporções de agrupamentos de códigos HTTP (2xx, 4xx e 5xx).
- Latência: Média e percentis estatísticos (mediana, p50, p95 e p99) para descrever a distribuição e acomodar valores extremos sem distorcer a observação central.
- Contexto Temporal: Quantidade de consumidores distintos e representação do instante (hora do dia e dia da semana). Para que os algoritmos baseados em distância interpretem corretamente a continuidade temporal (preservando a proximidade natural entre 23h e 00h), os campos de tempo são convertidos em componentes contínuos mediante codificação cíclica trigonométrica (seno e cosseno).
- Variação Temporal: Diferenças absolutas ou relativas da latência e da taxa de erros em relação à janela imediatamente anterior, além de médias e desvios-padrão móveis que capturam a tendência recente.

A viabilidade dessa extração requer que a amostra de dados possua um tamanho moderado, cobrindo ao menos um ciclo semanal completo, garantindo que os atributos de dia da semana possuam variância suficiente para informar o modelo.

4.4 Definição dos estados comportamentais

Os estados operacionais investigados compreendem: Normalidade Contextual, Transição e Degradação Residual. O estado "Normalidade Contextual"não é monolítico; ele é subdividido em regimes descobertos empiricamente nos dados (por exemplo, horário comercial, baixo volume noturno, pico de regras de negócio ou janelas de manutenção de mainframe).

A quantidade e a identidade desses regimes normais não são fixadas previamente. Elas são determinadas empiricamente pela quantidade de agrupamentos estáveis identificados por algoritmos baseados em densidade. Caso a amostra de uma API específica apresente baixa cardinalidade e revele poucos regimes (exemplo: apenas 2 ou 3), o experimento acatará essa estrutura natural, abstendo-se de forçar a criação artificial de múltiplos agrupamentos.

4.5 Critério operacional de classificação residual

Para categorizar as janelas temporais, estabelece-se o seguinte critério operacional:

- Normalidade Contextual: A janela é classificada no regime normal correspondente quando sua distância em relação ao centro do agrupamento mais próximo encontra-se dentro do intervalo de tolerância observado para aquele cluster. Sendo este um conjunto de estados normais para compreender os regimes possíveis de operação autêntica.
- Transição: O estado é atribuído quando a janela apresenta um distanciamento do centroide, mas trata-se de um desvio isolado que não se sustenta ao longo de múltiplas janelas temporais.
- Degradação Residual: O estado é atribuído quando a janela apresenta características anômalas e permanece fora dos limites de normalidade por múltiplas janelas consecutivas, indicando uma deterioração contínua e persistente do serviço.

Dado que o registro histórico formal de incidentes pode não estar disponível, a validação do critério de degradação residual será realizada, inicialmente, de forma indireta via inspeção qualitativa manual. Contudo, para viabilizar o treinamento supervisionado rigoroso, será empregada a injeção sintética controlada de degradações (perturbação matemática sobre janelas normais) visando a construção de um ground truth confiável para a classificação.

4.6 Experimentos

O desenho experimental estrutura-se em cinco testes principais, baseados estritamente em validação cronológica (divisão em blocos de tempo) para evitar o vazamento temporal de dados:

- Experimento 1 Descoberta de regimes: Comparação de algoritmos de agrupamento (particionais, hierárquicos e baseados em densidade) sobre o vetor de atributos para extrair os regimes normais autênticos da API.
- Experimento 2 Classificação dos estados: Este experimento treina classificadores supervisionados (modelos lineares, árvores de decisão e ensembles avançados) para categorizar o estado da janela atual. Os resultados serão contrastados com baselines de regras simples (limiares fixos, média ponderada por desvio-padrão, percentis e regras puramente sazonais).
- Experimento 3 - Importância das características: Análise da contribuição de cada atributo para a classificação dos estados, calculada por meio das métricas nativas dos modelos de árvore e de valores focados em interpretabilidade.
- Experimento 4 Comparação temporal (Exploratório): Repetição dos Experimentos 1 e 2 testando agregações de 1, 5 e 15 minutos, a fim de avaliar a estabilidade dos regimes frente a diferentes granularidades, condicionado ao volume de requisições dos dados originais.
- Experimento 5 Generalização entre APIs (Exploratório): Avaliação da queda de desempenho ao aplicar o modelo treinado nos dados de uma API do Banco do Brasil em uma segunda API distinta do mesmo ecossistema corporativo.

4.7 Métricas

A avaliação de desempenho seleciona métricas robustas contra o desbalanceamento intrínseco aos estados de falha, consolidando os resultados de forma lógica:

- Agrupamento (Experimento 1): Utilização do Coeficiente de Silhouette e dos índices de Davies-Bouldin e Calinski-Harabasz para aferir a qualidade da separação e a coesão dos regimes descobertos.
- Classificação (Experimentos 2 a 5): Aferição por meio de Precisão, Recall, Fl-score (macro e por classe), Área sob a Curva de Precisão-Recall (PR-AUC) e Matriz de Confusão.
- Critério de Consolidação: Para evitar que o desempenho reportado seja inflado por uma sequência longa de instabilidades altamente correlacionadas, janelas temporalmente adjacentes classificadas no mesmo estado residual serão agrupadas em um único episódio operacional antes do cômputo das métricas finais de classificação.

Referências

[1] AUDIBERT, J.; MICHIARDI, P.; GUYARD, F.; MARTI, S.; ZULUAGA, M. A. USAD: UnSupervised Anomaly Detection on Multivariate Time Series. In: Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining (KDD '20). New York: ACM, 2020.

[2] DU, M.; LI, F.; ZHENG, G.; SRIKUMAR, V. DeepLog: Anomaly Detection and Diagnosis from System Logs through Deep Learning. In: Proceedings of the 2017 ACM SIGSAC Conference on Computer and Communications Security (CCS '17). New York: ACM, 2017. p. 1285-1298.

[3] MENG, W.; LIU, Y.; ZHU, Y.; ZHANG, S.; PEI, D.; LIU, Y.; CHEN, Y.; ZHANG, R.; TAO, S.; SUN, P.; ZHOU, R. LogAnomaly: Unsupervised Detection of Sequential and Quantitative Anomalies in Unstructured Logs. In: Proceedings of the Twenty-Eighth International Joint Conference on Artificial Intelligence (IJCAI-19). Macao: IJCAI Organization, 2019. p. 4739-4745. DOI: 10.24963/ijcai.2019/658.

[4] SIFFER, A.; FOUQUE, P.-A.; TERMIER, A.; LARGOUET, C. Anomaly Detection in Streams with Extreme Value Theory. In: Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '17). New York: ACM, 2017. p. 1067-1075.

[5] SOMASHEKAR, G.; DUTT, A.; ADAK, M.; LORIDO BOTRAN, T.; GANDHI, A. GAMMA: Graph Neural Network-Based Multi-Bottleneck Localization for Microservices Applications. In: Proceedings of the ACM Web Conference 2024 (WWW '24). New York: ACM, 2024. p. 3085-3095.

[6] WANG, Y.; MÄNTYLÄ, M. V.; DEMEYER, S.; BEYAZIT, M.; KISAAKYE, J.; NYYSSÖLÄ, J. Cross-System Categorization of Abnormal Traces in Microservice-Based Systems via Meta-Learning. Proceedings of the ACM on Software Engineering, v. 2, FSE, artigo FSE027, 2025.

[7] ZHANG, C.; PENG, X.; SHA, C.; ZHANG, K.; FU, Z.; WU, X.; LIN, Q.; ZHANG, D. DeepTraLog: Trace-Log Combined Microservice Anomaly Detection through Graph-Based Deep Learning. In: Proceedings of the 44th International Conference on Software Engineering (ICSE '22). New York: ACM, 2022. p. 623-634.

[8] ZHANG, W. et al. Intelligent Site Reliability Engineering: A Multi-Agent LLM Framework for Automated Incident Analysis and Root Cause Determination. 2025. Disponível em: https://www.researchgate.net/publication/399119176 Intelligent Site Reliability Engin eering A Multi- agent LLM Framework for Automated Incident Analysis and Root Cause Determi nation. Acesso em: 10 maio 2026.