Normalidade Contextual em APIs: Caracterização de Regimes a partir de Access Logs para Apoio à Análise de Incidentes

Diego Paz Casagrande
Universidade de Brasília
Brasília, DF, Brasil

RESUMO

Quando um incidente é aberto, uma das primeiras perguntas do operador é se as APIs envolvidas estão operando normalmente e, se não estão, qual indicador saiu do padrão. A resposta não é trivial, porque o comportamento de uma API varia legitimamente com o horário, o calendário e os processamentos em lote. Este trabalho investiga se *API Access Logs* (AALs) agregados por minuto permitem responder, no instante do registro do incidente, se cada recurso de API está em um de seus regimes normais (Normal) ou fora deles (Residual); qual indicador é responsável: erros de negócio (4xx), erros de sistema (5xx) ou latência; e desde quando. Seguindo o CRISP-DM, propõe-se um perfil de normalidade contextual por recurso (mediana e MAD por hora e tipo de dia), com um limite próprio para cada indicador calibrado por validação cruzada, e uma expansão retroativa em faixas de 15 min a 4 h para estimar o início do desvio. Em 2,3 milhões de registros de 12 recursos de produção, os testes confirmaram regimes ligados à hora do dia. Em 7.200 consultas simuladas (3.600 incidentes com falhas injetadas e 3.600 controles), a decisão sobre os 15 minutos anteriores ao registro teve especificidade de 96,8% e apontou o indicador correto em 96,4% dos casos detectados; o início real ficou dentro da zona estimada em 92,9% deles. A sensibilidade, porém, foi de 38%: alta para erros de sistema (até 86%) e baixa para latência (até 27%).

PALAVRAS-CHAVE

Mineração de Dados; API Access Log; Normalidade Contextual; Análise de Incidentes; CRISP-DM; Regimes Operacionais.

1 INTRODUÇÃO

A arquitetura dos sistemas modernos consolidou o uso de APIs (*Application Programming Interfaces*) como mecanismo fundamental de integração em sistemas distribuídos. Em ambientes corporativos de grande porte, as APIs medeiam desde requisições de clientes externos até transações entre sistemas legados e modernos. No Banco do Brasil, cerca de 30 mil APIs são executadas diariamente, conectando soluções de negócio que combinam plataformas em nuvem e *mainframe*.

1.1 Contexto

Requisições processadas por gateways de API geram registros com o instante da execução, o recurso acessado, o código de resposta, o tempo de processamento e o consumidor. Neste estudo, esses registros são denominados *API Access Logs* (AALs): o registro gerado pelo gateway para as requisições processadas, distinto do *execution log* e do log de aplicação. Os AALs estão disponíveis de forma padronizada para um conjunto amplo de APIs, sem instrumentação específica no código.

O comportamento de uma API não é estacionário. Volume, latência e proporção de erros variam com o horário, o dia da semana, os processamentos em lote e as janelas de manutenção. Uma taxa de erros que é normal na virada do dia, durante um lote, pode ser anormal às 10h de um dia útil.

1.2 Problema

Quando um incidente é registrado, o operador precisa responder, para cada API envolvida: *no momento em que o incidente foi aberto, a API está operando dentro de um regime normal?* Se não está, importa saber *qual indicador foi impactado*: erros de negócio (faixa 4xx), erros de sistema (faixa 5xx) ou latência; e *desde quando* o desvio acontece. Como informação complementar, interessa saber se o impacto é *generalizado* ou concentrado em um *consumidor específico*, com volume suficiente para alterar o resultado agregado da API.

Hoje essa resposta depende de consultar várias ferramentas e de conhecer o comportamento típico de cada API [Zhang et al. 2025]. Limites fixos ou um único perfil de normalidade não distinguem a variação legítima (um lote à meia-noite, o volume menor no fim de semana) de um desvio real.

Do ponto de vista de mineração de dados, o problema consiste em: (1) caracterizar os regimes normais de cada recurso a partir de AALs agregados; (2) classificar o período imediatamente anterior ao registro de um incidente em dois estados: Normal (dentro de algum regime normal esperado para aquele contexto) ou Residual (todo o resto); e (3) quando Residual, identificar o indicador responsável e o início do desvio.

1.3 Motivação

Este trabalho complementa um projeto de mestrado sobre sistemas multiagente para apoio ao atendimento de incidentes. A literatura recente mostra agentes especializados em diferentes fontes de dados, coordenados para triagem e análise [Luo et al. 2025; Yu et al. 2025; Zhang et al. 2025]. Um desses agentes precisa de uma fonte confiável e explicável sobre o comportamento das APIs. O foco não é monitoração em tempo real nem a identificação da causa raiz, mas a *informação de contexto no instante do incidente*: dizer se cada recurso está em regime normal e, se não, qual indicador está impactado e desde quando. Essa informação abastece o operador e colabora para a análise do ocorrido.

1.4 Objetivos

Objetivo geral: caracterizar os regimes normais de cada recurso de API a partir de Access Logs agregados e, no instante do registro de um incidente, informar se o recurso está em regime normal e, se não, qual indicador foi impactado e desde quando.

Objetivos específicos:

- Verificar se cada recurso apresenta vários regimes normais ligados ao contexto (hora e tipo de dia).
- Construir um perfil de normalidade por recurso e contexto e uma regra de decisão Normal/Residual explicável.
- Identificar o indicador responsável (4xx, 5xx, latência) e estimar o início do desvio.
- Avaliar o método em cenários de incidente simulados e compará-lo a baselines simples.
- Disponibilizar a informação em formato estruturado para um agente ou operador.

1.5 Questões de pesquisa

- **RQ1.** AALs agregados permitem caracterizar os regimes normais de cada recurso e decidir, no instante do registro, se o recurso está em regime normal?
- **RQ2.** Quando o recurso não está em regime normal, o método identifica corretamente o indicador responsável (4xx, 5xx, latência) e o início do desvio?
- **RQ3.** Qual o período anterior ao registro (15, 30 ou 60 min) mais adequado para a decisão, e como o intervalo entre o início da degradação e o registro afeta o resultado?

1.6 Contribuições e organização

As contribuições são: (i) a caracterização empírica dos regimes de 12 recursos de API de produção; (ii) um método simples e explicável, sem rótulos, que decide o estado de um recurso no instante do registro e aponta o indicador impactado; (iii) uma estimativa de início por expansão retroativa; e (iv) um protocolo de avaliação com cenários de incidente simulados. A Seção 2 discute os trabalhos correlatos; a Seção 3, a metodologia; a Seção 4, os resultados; a Seção 5, a discussão; a Seção 6, as ameaças à validade; e a Seção 7 conclui.

2 TRABALHOS CORRELATOS

2.1 Análise e mineração de logs

Du et al. [2017] propuseram o DeepLog, que emprega redes LSTM para aprender sequências normais de eventos de log e sinalizar desvios. Meng et al. [2019] propuseram o LogAnomaly, que combina informação semântica dos *templates* com a detecção de anomalias sequenciais e quantitativas. Ambos mostram que logs carregam informação suficiente para caracterizar comportamento, mas operam sobre sequências de eventos de logs de sistema, e não sobre AALs agregados; tampouco tratam da coexistência de múltiplos regimes normais.

2.2 Normalidade e séries temporais

Siffer et al. [2017] propuseram o SPOT/DSPOT, que calibra limiares a partir da cauda da distribuição com Teoria de Valores Extremos e os adapta a séries não estacionárias, mas sem identificar os contextos que fazem o limiar variar. Audibert et al. [2020] propuseram o USAD, baseado em autoencoders para séries multivariadas, centrado em escores de anomalia, e não na interpretação de regimes. Wang et al. [2025] discutem a dificuldade de generalizar modelos entre sistemas distintos, o que reforça a opção por perfis ajustados por recurso.

Tabela 1: Fases do CRISP-DM, notebooks e técnicas.

Fase	Notebook: conteúdo (técnica)
Negócio, Dados	01: problema, critérios de sucesso, qualidade da base
Preparação	02: consolidação, atributos por janela, p95 de latência
Dados, Modelagem	03: regimes (Kruskal-Wallis; k-means)
Modelagem	04: perfil contextual (mediana/MAD); limite por indicador (validação cruzada)
Preparação	05: cenários de incidente (injeção de falhas)
Avaliação	06: estado, indicador, início (expansão retroativa); IC de Wilson, McNemar
Implantação	07: consulta estruturada para o agente

2.3 Modelagem comportamental de microsserviços

O DeepTraLog [Zhang et al. 2022] combina *traces* e logs em grafos, e o GAMMA [Somashekar et al. 2024] localiza gargalos com redes neurais em grafos. Esses trabalhos pressupõem *traces*, logs internos ou métricas de infraestrutura, que extrapolam o AAL isolado.

2.4 Incidentes e sistemas multiagente

O Triangle [Yu et al. 2025] usa múltiplos agentes na triagem de incidentes; o OpsAgent [Luo et al. 2025] e o trabalho de Zhang et al. [2025] coordenam agentes especializados para análise de incidentes. Esses sistemas dependem de fontes que resumam o estado dos componentes de forma confiável. O presente trabalho se posiciona como uma dessas fontes: transforma AALs em evidência explicável sobre o estado de cada recurso no momento do incidente.

2.5 Síntese e lacuna

Os trabalhos revisados tratam o comportamento, predominantemente, a partir de um único perfil de normalidade; dependem de fontes além do AAL; ou focam na causa raiz. Nenhum investiga, a partir exclusivamente do AAL, a caracterização de múltiplos regimes normais por recurso e o seu uso para informar, no instante de um incidente, o estado do recurso, o indicador impactado e o início do desvio.

3 METODOLOGIA

O trabalho segue o CRISP-DM [Chapman et al. 2000; Wirth and Hipp 2000]. Cada fase foi implementada em um *notebook* Jupyter com parâmetros explícitos e sementes fixas (Tabela 1). A análise é sempre *por recurso*. Optou-se por técnicas simples de explicar: seis no total, todas disponíveis em pandas, SciPy e scikit-learn [Pedregosa et al. 2011].

3.1 Entendimento do negócio

A decisão apoiada é: *no instante do registro do incidente, o recurso está em regime normal? Se não, qual indicador foi impactado (erros 4xx, erros 5xx, latência) e desde quando?* A abrangência (consumidor específico ou generalizado) é informação complementar. Os critérios de sucesso foram definidos antes da modelagem (Tabela 6).

Tabela 2: Indicadores usados na decisão e direção desfavorável.

Indicador	Definição	Direção
volume	log(1+transações), na escala horária	alta e queda
erros 4xx	transações 4xx / total (erros de negócio)	alta
erros 5xx	transações 5xx / total (erros de sistema)	alta
latência p95	log(1+p95 das médias por minuto×cliente)	alta

Como não havia histórico de incidentes, a avaliação usa cenários simulados com falhas injetadas.

3.2 Entendimento dos dados

A base contém AALs de produção de 12 recursos (`CD_RCS_CAT`), identificados aqui por E01 a E12 em ordem decrescente de volume. **Cada linha é um agregado por minuto × recurso × código HTTP × cliente**: o total de execuções no minuto (`QT_TTL_TRAN`) e o tempo médio dessas execuções (`QT_TMP_MEDI_EXEA`). Não há registros por requisição. O identificador de cliente foi anonimizado por SHA-256 com semente, sem payloads nem dados pessoais. Os horários, em UTC, foram convertidos para o horário de Brasília (UTC−3) antes de qualquer corte temporal.

São 2.300.414 linhas de 31/07/2026 21h a 08/09/2026 20h59, com 1.825 clientes. As respostas 2xx somam 79,3% das transações; 4xx, 20,4%; 5xx, 0,28%. Há 17.265 linhas excedentes com a mesma chave (minuto, recurso, código, cliente), 0,95% do volume, que parecem gravações parciais do mesmo minuto. Quatro recursos (E02, E03, E06, E11) têm o último registro em 03/09 às 07:11. Não há valores nulos; 33 linhas têm latência média acima de 60 s e foram mantidas, pois o método usa estatísticas robustas. O volume varia muito entre recursos: a mediana por 15 min vai de 36 transações (E11) a 1.876 (E02).

3.3 Preparação dos dados

As chaves repetidas foram consolidadas (soma do volume e média de latência ponderada). Os registros foram agregados em janelas de 1 h (10.695 janelas recurso × hora) e em períodos de 15 e 30 min. A decisão usa quatro indicadores (Tabela 2). O *contexto* de cada período é o par (tipo de dia, hora), com tipo de dia *útil* ou *não útil* (sábado, domingo e feriado). Agosto de 2026 é o treino; os cenários de teste usam 01 a 08/09.

Latência p95. Como não há latência por requisição, o p95 é o percentil 95 das latências médias por minuto × cliente das respostas 2xx, ponderado pelo número de execuções. É um p95 *das médias*, não das requisições, e tende a subestimar a cauda real; mas é consistente entre períodos e sensível a degradações que atingem só parte dos minutos ou dos consumidores. Na mediana, ele é 1,43 vez a latência média.

3.4 Modelagem

Regimes (descritivo). O teste de Kruskal-Wallis [Kruskal and Wallis 1952], com correção de Bonferroni [Dunn 1961], verifica se cada indicador muda entre as 24 horas dos dias úteis. Para cada recurso, o k-means [Lloyd 1982] agrupa as janelas de 1 h de agosto usando apenas os indicadores padronizados, com $k \in [2, 8]$ escolhido pelo coeficiente de silhouette [Rousseeuw 1987]. O contexto não entra no agrupamento; ele é usado depois, para nomear cada regime (nível de volume, tipo de dia e horas em que predomina). O k-means é descritivo: a decisão usa o perfil contextual.

Perfil de normalidade contextual. Para o recurso r, o contexto c e o indicador a, o perfil guarda a mediana $m_a(r, c)$ e a escala robusta [Leys et al. 2013]

$$s_a(r, c) = \max\{1{,}4826 \cdot \mathrm{MAD}_a(r, c),\ \varepsilon_a\}, \tag{1}$$

calculadas nas janelas de 1 h de agosto, em que ε_a é um piso que evita divisões por valores próximos de zero. Para um período w, o desvio de cada indicador, contado só na direção desfavorável, é

$$z_a(w) = \frac{x_a(w) - m_a(r, c)}{s_a(r, c)}, \tag{2}$$

$$d_a(w) = \begin{cases} |z_a(w)| & \text{volume,} \\ \max\{z_a(w), 0\} & \text{demais indicadores.} \end{cases} \tag{3}$$

Períodos de 15 e 30 min usam o mesmo perfil de 1 h: o volume é convertido para a escala horária, e as taxas e o p95 são usados diretamente.

Limite por indicador. Os indicadores têm variabilidades muito diferentes; em alguns recursos a taxa de 4xx tem picos reais frequentes. Por isso, cada indicador tem um limite próprio no recurso, $L_{r,a} = \max\{3,\ Q_{0,99}(d_a)\}$: o percentil 99 dos seus desvios em agosto, calculados fora da amostra. O limite é recalculado para cada tamanho de período (15, 30 e 60 min), porque períodos curtos variam mais. O período é Residual se algum indicador passa do seu limite ($d_a / L_{r,a} > 1$); o **indicador responsável** é o que mais passou, em múltiplos do limite.

Calibração sem vazamento. Os desvios fora da amostra vêm de validação cruzada com quatro dobras semanais em agosto: o perfil é ajustado em três semanas e avalia a restante. O modelo final é ajustado com agosto inteiro. Com essa regra, 3,5% dos períodos de 15 min de agosto são Residual.

Início estimado (expansão retroativa). A partir do registro, o método avalia faixas disjuntas cada vez mais distantes: 0–15, 15–30, 30–60 min e, depois, de hora em hora até 4 h, cada uma com o limite do seu tamanho. A busca para na primeira faixa Normal, e o início é estimado entre o começo da última faixa residual e o fim dessa faixa normal. Por exemplo: faixas 0–15 e 15–30 residuais e 30–60 normal indicam que o desvio começou entre 15 e 60 min antes do registro.

Abrangência (complementar). Para erros 4xx ou 5xx, o desvio é atribuído a um *consumidor específico* quando o cliente com mais erros concentra ao menos 80% deles e essa fatia supera em pelo menos 20 pontos percentuais a sua fatia do volume; caso contrário, é *generalizado*. Recursos com menos de três clientes ativos ficam indeterminados.

3.5 Avaliação

Cenários de incidente. Cada cenário simula um incidente: uma degradação começa em t_0 e o incidente é registrado em $t = t_0 + \Delta$,

Tabela 3: Motivos injetados (baixa / média / alta).

Motivo	Intensidade
4xx generalizado	5% / 15% / 40% das 2xx viram 400
4xx de 1 consumidor	30% / 60% / 90% das 2xx do consumidor viram 400
5xx generalizado	5% / 15% / 40% das 2xx viram 503
5xx de 1 consumidor	30% / 60% / 90% das 2xx do consumidor viram 503
Latência	tempo de execução ×1,5 / ×2,5 / ×4

O consumidor afetado é sorteado com probabilidade proporcional ao seu volume.

com atraso $\Delta \in \{15, 30, 60, 120\}$ min. O instante de registro é sorteado entre 01/09 às 04h e o fim dos dados de cada recurso. As falhas (Tabela 3) são aplicadas nos registros por minuto × cliente e depois reagregadas, para que os indicadores e a abrangência reajam como numa falha real. Foram gerados 5 cenários por recurso × motivo × intensidade × atraso (3.600 incidentes) e 3.600 consultas de controle, em instantes sem falha injetada. Cada cenário é independente, sobre uma cópia dos dados.

Métricas. Para cada cenário, avalia-se o período $[t - L, t)$, com $L = 15$ min como principal e 30 e 60 min para comparação. As métricas são: *sensibilidade* (incidentes com saída Residual); *especificidade* (controles com saída Normal); *acurácia do indicador* (indicador apontado igual ao do motivo injetado, entre os detectados); *acerto do início* (início real dentro da zona estimada); e *acurácia da abrangência*. As proporções têm intervalos de confiança de Wilson a 95% [Wilson 1927].

Baselines. Com o mesmo tratamento de limites e calibração: (i) *z-score global*, o mesmo perfil sem contexto (um por recurso); e (ii) *semana anterior*, que compara com o mesmo período sete dias antes. A comparação usa o teste exato de McNemar [McNemar 1947] sobre os acertos de estado nos mesmos cenários.

4 RESULTADOS

4.1 Regimes normais por recurso (RQ1)

A Figura 1 mostra perfis horários típicos: lote na virada do dia (E01), lote às 15–16h (E05), padrão comercial em dias úteis que desaparece nos dias não úteis (E02, E12). A Figura 2 mostra que cada recurso tem sua própria assinatura horária de volume e de latência. Nos dias úteis, 85% dos testes de Kruskal-Wallis (recurso × indicador) foram significativos após Bonferroni. O efeito mediano (ε^2) foi grande para volume (0,39), erros 4xx (0,35) e latência p95 (0,27), e pequeno para erros 5xx (0,07), que em dias normais são raros.

O k-means encontrou de 2 a 7 regimes por recurso (mediana 3,5; silhouette médio 0,59; Tabela 4). A Figura 3 ilustra o E02: um regime de volume alto das 8 às 19h dos dias úteis, um de volume médio no restante do tempo e um regime à 0h com taxa de 5xx elevada. Esse último é *normal* para aquele horário: é o tipo de variação legítima que um limite fixo trataria como falha.

4.2 Limites por indicador

Os limites (Figura 4) variam de 3 a 86 em z. Limites altos revelam indicadores com picos reais frequentes em agosto: erros 4xx em E04 (85) e E07 (49), erros 5xx em E10 e E12 (cerca de 20), e latência p95 em E02 e E03 (18 a 24). Nesses casos, só desvios grandes daquele indicador são marcados como Residual. Em agosto, fora da amostra, 3,3% das janelas de 1 h foram residuais, com o volume (90 janelas), a latência (82), os erros 4xx (75) e os erros 5xx (44) como indicadores responsáveis.

4.3 Estado no instante do registro (RQ1)

A Tabela 5 e a Figura 5 resumem a decisão. Com a faixa de 15 min, o perfil contextual classificou corretamente 96,8% dos controles como Normal e sinalizou como Residual 38,1% dos incidentes (44,2% nas intensidades média e alta). Nos acertos de estado, ele supera o z-score global em todas as faixas (McNemar: $p = 0{,}015$ em 15 min; $p < 0{,}001$ em 30 e 60 min) e a semana anterior em 30 min ($p = 0{,}009$), empatando com esta em 15 e 60 min ($p = 0{,}35$ e 0,38).

Ponto de operação. O plano previa limites que gerassem 1% de alarmes em agosto (multiplicador $c \approx 1{,}7$ sobre o percentil 99). Nesse ponto, a especificidade foi de 99,3%, mas a sensibilidade caiu para 27,7%, e o z-score global detectou mais (30,4%). Como a consulta só é feita quando já existe um incidente aberto, adotou-se o ponto em que o limite é o próprio percentil 99 ($c = 1$), trocando 2,5 pontos de especificidade por 10 pontos de sensibilidade. A Figura 6 mostra os três pontos avaliados: com 1% o perfil contextual detecta menos que os baselines, com 2% empata e com 5% os supera.

Por motivo. A sensibilidade depende muito do motivo (Figura 7). Erros de sistema generalizados são detectados em 56% a 86% dos casos, conforme a intensidade, e erros 5xx de um consumidor em 43% a 58%. Erros de negócio têm detecção de 4% a 39% (generalizados) e de 22% a 33% (um consumidor), porque vários recursos já têm taxas altas e variáveis de 4xx. A latência é o motivo mais difícil: 5% a 27%. Por recurso (Tabela 4), a sensibilidade vai de 6% (E10, com apenas dois clientes e picos reais de 5xx) a 75% (E01).

4.4 Tamanho da faixa e atraso do registro (RQ3)

A faixa mais curta é a melhor quando o incidente é registrado logo após o início da degradação (Figura 8): com atraso de 15 min, a sensibilidade (intensidades média e alta) é de 48% com a faixa de 15 min, contra 31% com a de 60 min, que mistura minutos normais e degradados. Com atraso de 60 ou 120 min, a faixa de 60 min fica ligeiramente melhor (47% contra 42%), por reduzir o ruído. Na média, a faixa de 15 min é a mais adequada como decisão principal.

4.5 Indicador responsável e início (RQ2)

Quando o recurso é sinalizado como Residual, o indicador apontado é o do motivo injetado em 96,4% dos casos [95,3; 97,3] (Figura 9): 99% para 5xx generalizado, 97% para 5xx de um consumidor, 93–95% para 4xx e 89% para latência. Os erros restantes provavelmente vêm de desvios reais no mesmo período, como uma queda de volume. A acurácia é menor em E06 (74%) e E03 (86%), recursos com muita variação natural em outros indicadores.

A expansão retroativa (Figura 10) colocou o início real dentro da zona estimada em 92,9% dos casos detectados [91,4; 94,1]: 99% quando a degradação começou 15 min antes do registro, 100% com 30 min, 88% com 60 min e 83% com 120 min (Figura 11). Os erros são

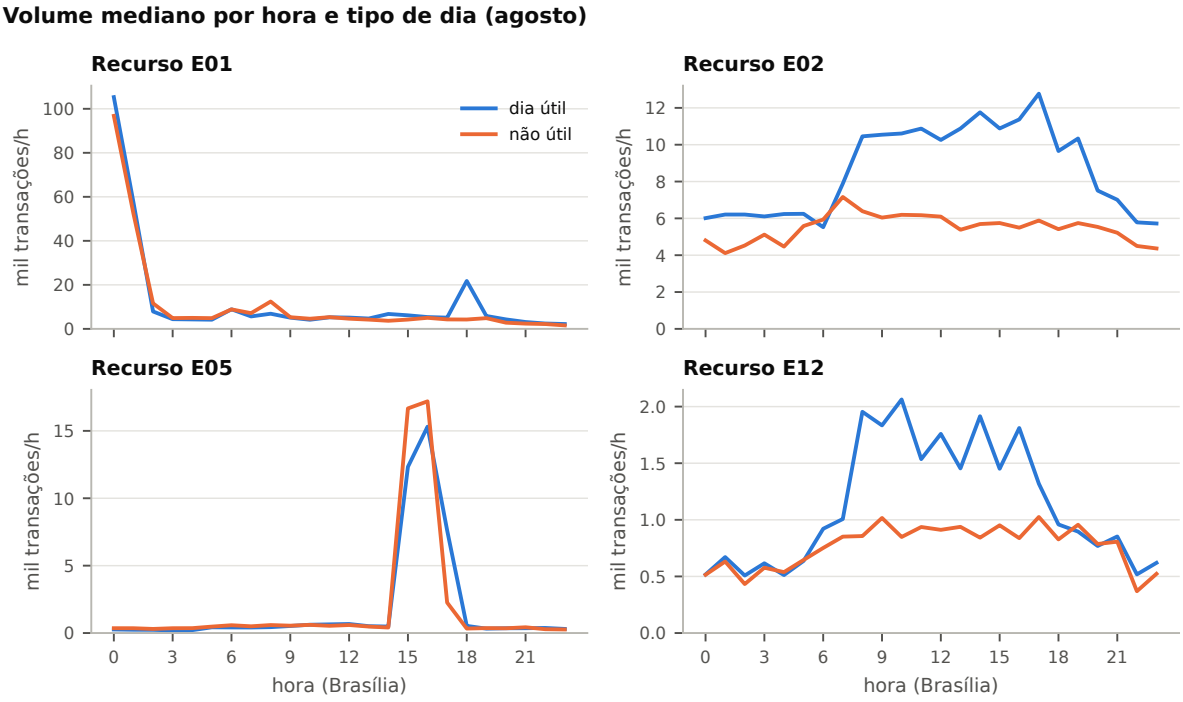


Figura 1: Volume mediano por hora e tipo de dia em agosto, em quatro recursos.

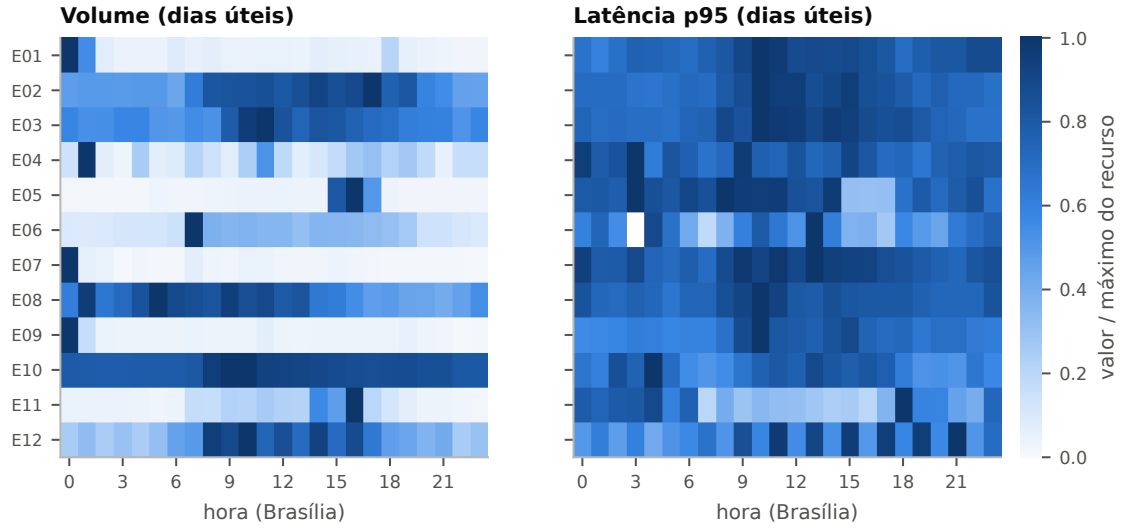


Figura 2: Volume e latência p95 medianos por hora em dias úteis, normalizados pelo máximo de cada recurso.

quase sempre subestimações: uma faixa intermediária sai Normal, a busca para cedo e o início é estimado mais perto do registro do que de fato ocorreu.

Abrangência (complementar). Entre os erros 4xx e 5xx detectados com o indicador correto, a abrangência foi classificada corretamente em 80,4% [78,1; 82,5]. Os erros generalizados são reconhecidos como tais em 91–94% dos casos; os de um consumidor, em 60% (4xx) e 69% (5xx). Os demais aparecem como generalizados

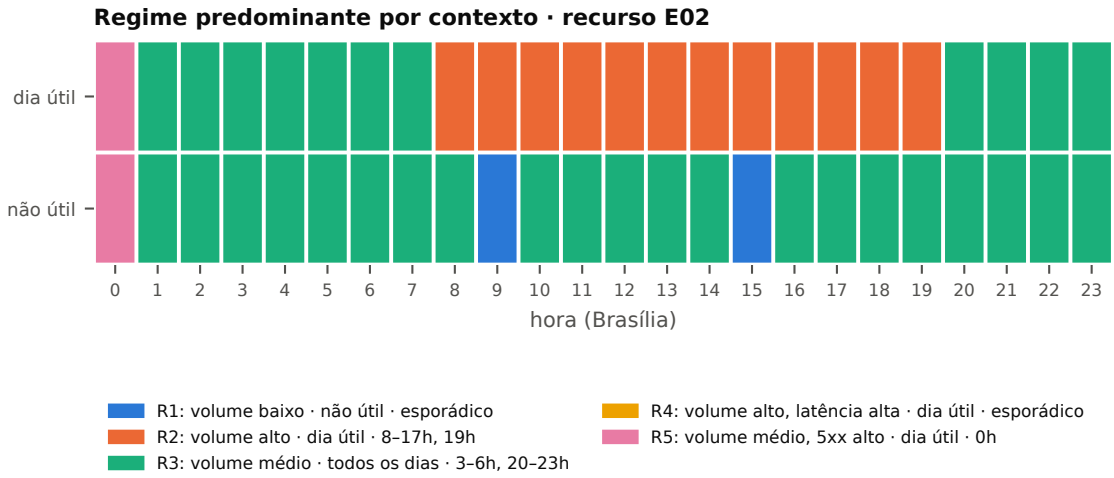


Figura 3: Regime predominante (k-means com os indicadores) por tipo de dia e hora no recurso E02.

Tabela 4: Resumo por recurso: participação no volume, clientes, transações medianas por 15 min, regimes e resultados no registro (faixa de 15 min).

Recurso	Vol. (%)	Clientes	Trans./15 min	Regimes (k)	Silhouette	Sensib.	Sensib. média/alta	Especif.	Acurácia indicador
E01	36,1	36	1.198	6	0,45	0,75	0,85	0,96	0,98
E02	20,1	524	1.876	5	0,54	0,17	0,22	0,98	0,94
E03	5,7	221	502	4	0,58	0,29	0,34	0,95	0,86
E04	4,9	20	208	5	0,44	0,38	0,40	0,97	0,98
E05	4,8	18	104	3	0,59	0,66	0,74	0,98	0,99
E06	4,7	735	313	3	0,69	0,14	0,16	0,94	0,74
E07	4,7	36	146	2	0,88	0,42	0,48	0,98	0,98
E08	4,6	38	314	5	0,38	0,50	0,56	0,96	0,97
E09	4,1	27	142	2	0,85	0,68	0,78	0,96	0,99
E10	4,0	2	263	7	0,38	0,06	0,08	0,99	0,94
E11	3,9	575	36	3	0,56	0,21	0,24	0,96	0,95
E12	2,4	735	188	2	0,74	0,31	0,44	0,98	0,97

Tabela 5: Estado no registro por método e faixa anterior ao registro, em % (IC de Wilson a 95% entre colchetes). 3.600 incidentes e 3.600 controles.

Método	Faixa L	Sensibilidade	Sensibilidade (média/alta)	Especificidade
Perfil contextual (proposto)	15 min	**38,1** [36,6; 39,7]	**44,2** [42,2; 46,2]	96,8 [96,1; 97,3]
	30 min	37,1 [35,5; 38,7]	43,5 [41,6; 45,5]	97,7 [97,2; 98,1]
	60 min	34,7 [33,2; 36,3]	40,7 [38,8; 42,7]	97,9 [97,3; 98,3]
z-score global	15 min	36,2 [34,7; 37,8]	41,8 [39,8; 43,7]	97,4 [96,9; 97,9]
	30 min	34,4 [32,9; 36,0]	39,8 [37,9; 41,8]	98,6 [98,2; 99,0]
	60 min	32,3 [30,8; 33,9]	37,7 [35,7; 39,6]	98,2 [97,8; 98,6]
Semana anterior	15 min	36,9 [35,4; 38,5]	41,9 [39,9; 43,9]	97,4 [96,9; 97,9]
	30 min	35,8 [34,3; 37,4]	41,5 [39,5; 43,4]	97,6 [97,1; 98,1]
	60 min	33,9 [32,4; 35,5]	39,8 [37,9; 41,8]	98,2 [97,7; 98,6]

porque, nesses recursos, outros consumidores já tinham erros no mesmo período.

4.6 Saída para o agente e evento real

A consulta produz um documento estruturado. A Figura 12 mostra, resumida, a saída do cenário da Figura 10.

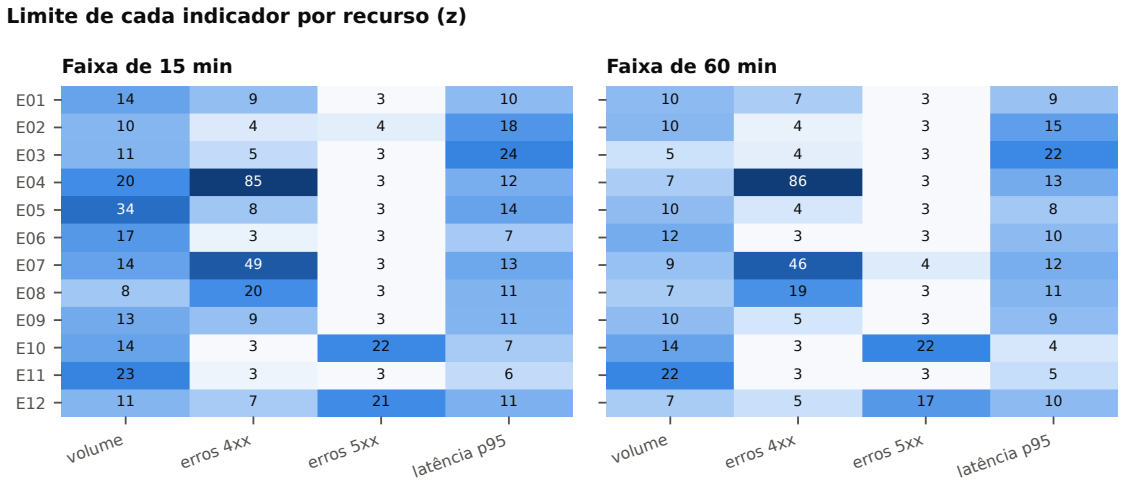


Figura 4: Limite de cada indicador por recurso (z, percentil 99 fora da amostra em agosto, mínimo 3), para períodos de 15 e de 60 min.

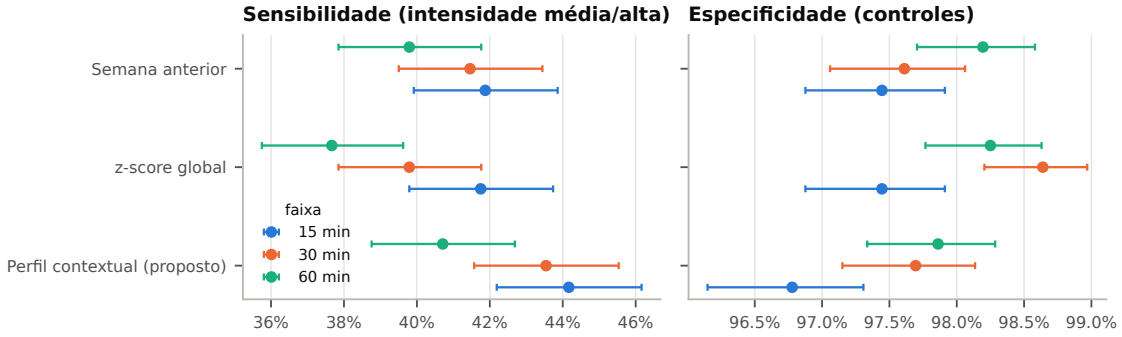


Figura 5: Sensibilidade (intensidades média e alta) e especificidade por método e faixa, com IC de Wilson a 95%.

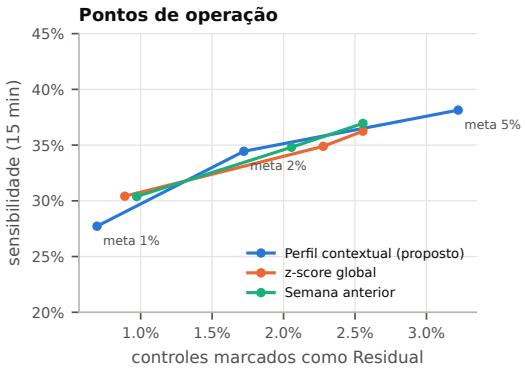


Figura 6: Sensibilidade contra controles marcados como Residual (faixa de 15 min), para metas de 1%, 2% e 5% de alarmes em agosto.

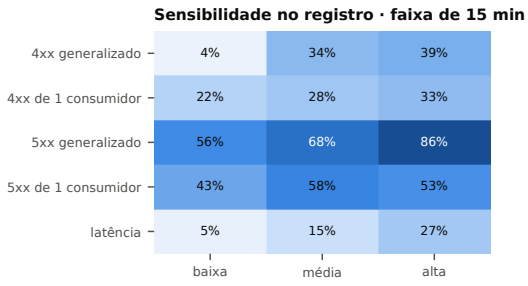


Figura 7: Sensibilidade no registro (faixa de 15 min) por motivo e intensidade.

Nos dados reais do teste, sem injeção, a consulta para o E02 às 01h45 de 02/09 retornou Residual por erros 5xx: 4,1% nos 15 min anteriores (faixa normal de 0 a 1,5%), em 15 dos 26 consumidores ativos. Chama a atenção que o E02 tem um regime normal com

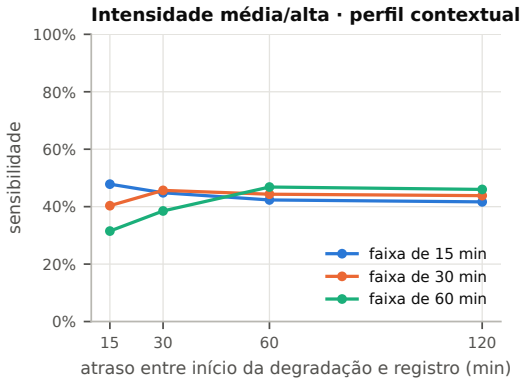


Figura 8: Sensibilidade (intensidades média e alta) por atraso entre o início da degradação e o registro, para cada tamanho de faixa.

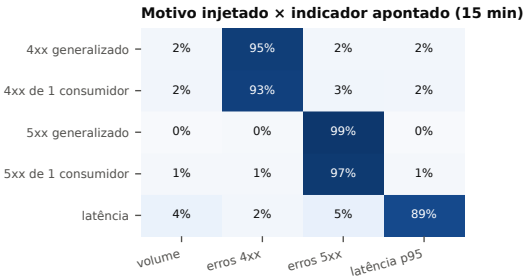


Figura 9: Motivo injetado contra indicador apontado (faixa de 15 min, casos detectados).

Tabela 6: Critérios de sucesso (faixa de 15 min).

Critério	Resultado	Atendido
Controles com saída Normal ≥ 95%	96,8%	sim
Sensibilidade (média/alta) ≥ 70%	44,2%	não
Acurácia do indicador ≥ 90%	96,4%	sim
Início real na zona estimada ≥ 70%	92,9%	sim
Sem perda significativa para os baselines	sem perda	sim

5xx elevado *à 0h*; o evento, uma hora depois, está fora dele. É um candidato a incidente real, a confirmar com a operação.

4.7 Critérios de sucesso

Quatro dos cinco critérios foram atendidos (Tabela 6). A sensibilidade ficou bem abaixo da meta.

5 DISCUSSÃO

RQ1: regimes e estado no registro. Os AALs agregados mostram regimes claros e ligados ao contexto, sobretudo à hora: lotes, horário comercial, madrugada e até regimes normais com erros elevados em horários específicos. O perfil contextual usa essa estrutura para decidir o estado de cada recurso no momento do incidente com alta especificidade (96,8%) e ganho, pequeno mas significativo, sobre o perfil sem contexto. Para o operador, isso tem duas leituras. Um resultado Residual é informação forte: raramente aparece sem motivo, e vem com o indicador certo. Um resultado Normal indica que o recurso dificilmente é a origem, mas não descarta degradações sutis, sobretudo de latência e erros de negócio.

RQ2: indicador e início. O ponto mais forte do método é a qualidade da informação quando ela é emitida: o indicador responsável é apontado corretamente em 96% dos casos, e o início é localizado na zona certa em 93%. A expansão retroativa é simples de explicar ("olhar para trás até encontrar um período normal") e dá ao operador uma resposta útil em faixas de 15 min a 1 h, que é a escala em que incidentes costumam ser abertos.

RQ3: tamanho da faixa. A faixa de 15 min é a melhor escolha como decisão principal, porque o incidente costuma ser aberto pouco depois do início da degradação. Faixas maiores só compensam quando a degradação já dura uma hora ou mais. Na prática, a faixa curta decide o estado e a expansão retroativa dá o horizonte.

Por que a latência é difícil. Uma latência quatro vezes maior produz $z \approx 8$, mas o limite de latência para 15 min fica entre 5 e 24, porque o p95 das médias por minuto tem caudas pesadas mesmo em dias normais: bastam alguns minutos lentos de um consumidor para elevá-lo. Um percentil por requisição, se disponível no gateway, e uma janela de referência maior para a latência são caminhos naturais de melhoria.

Por que alguns recursos detectam pouco. Recursos com picos reais frequentes de um indicador (4xx em E04 e E07; 5xx em E10 e E12) recebem limites altos para ele, e só desvios grandes aparecem. Em E10, com dois clientes e picos de 5xx, a sensibilidade foi de 6%. Nesses casos, o próprio limite é uma informação útil: ele diz ao operador que aquele indicador já é instável no recurso.

6 AMEAÇAS À VALIDADE

Falhas sintéticas. O desempenho mede a capacidade de detectar *os motivos injetados.* As intensidades variadas, os quatro atrasos e o grande número de cenários reduzem, mas não eliminam, esse viés.

Ponto de operação escolhido após o teste. A meta de alarmes passou de 1% para o ponto $c = 1$ (3,5% em agosto) depois de observados os resultados no teste. Os resultados com a meta original são relatados (Figura 6), e a comparação com os baselines usa a mesma regra para todos os métodos; ainda assim, trata-se de uma decisão pós-teste. Outras decisões anteriores (validação cruzada, limite por indicador) usaram apenas dados de agosto.

Controles e anomalias reais. As consultas de controle usam dados reais sem injeção, que podem conter anomalias reais (como a do E02), contadas como falso Residual. A especificidade é, portanto, uma estimativa conservadora.

Latência aproximada. O p95 é calculado sobre as médias por minuto e por cliente, e não sobre requisições; a cauda real tende a ser maior.

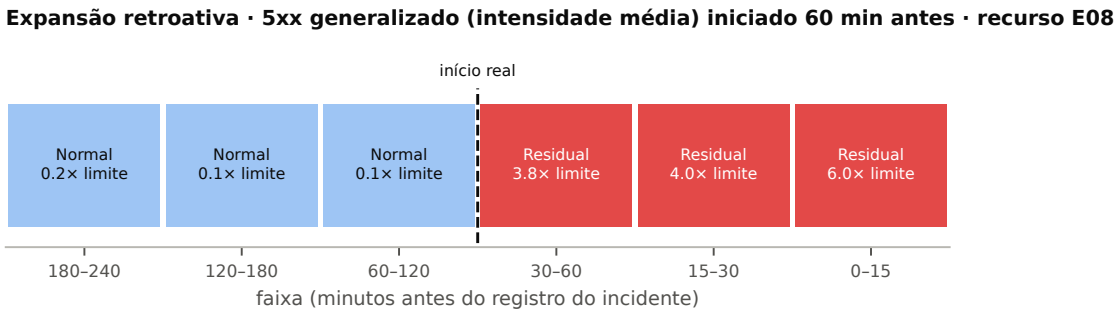


Figura 10: Expansão retroativa em um cenário de 5xx generalizado iniciado 60 min antes do registro (E08): as três faixas mais recentes são residuais e a de 60–120 min é normal, e o início é estimado entre 30 e 120 min antes.

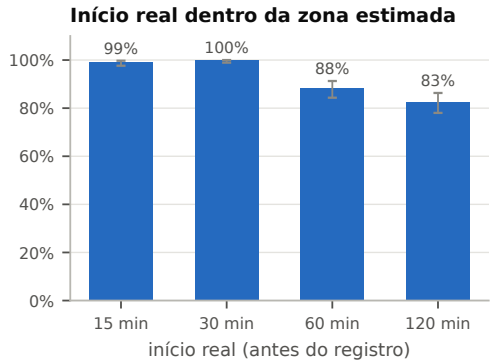


Figura 11: Início real dentro da zona estimada, por atraso (IC de Wilson a 95%).


```
{"recurso": "E08", "registro_incidente": "2026-09-04 10:47",
 "contexto": {"tipo_dia": "dia útil", "hora": "10h"},
 "estado": "Residual", "indicador_impactado": "erros 5xx",
 "evidencias": [{"indicador": "erros 5xx", "observado": "17.9%",
    "faixa_normal_p5_p95": ["0.0%", "0.1%"], "vezes_o_limite": 5.98}],
 "inicio_estimado": "entre 30 e 120 min antes do registro",
 "abrangencia": {"classificacao": "generalizado",
    "clientes_ativos": 13, "clientes_com_erro": 10},
 "motivo_estatistico": "O recurso E08 está fora do regime normal
   esperado para dia útil às 10h. Indicador impactado: erros 5xx
   — 17.9% nos 15 min anteriores ao registro (faixa normal 0.0% a
   0.1%), 5.98× o limite do recurso. O desvio começou entre 30 e
   120 min antes do registro. Os erros aparecem em 10 de 13
   consumidores ativos."}
```


Figura 12: Saída da consulta para o agente (resumida).

Treino curto e generalização. Um mês de dados resulta em cerca de 10 amostras por hora para os dias não úteis, e não permite capturar sazonalidades mensais. Os resultados vêm de uma organização e de 12 recursos, um deles com apenas dois clientes. A base não pode ser compartilhada; o código dos notebooks é independente dos dados.

7 CONSIDERAÇÕES FINAIS

Este trabalho mostrou que Access Logs agregados por minuto, sem *traces* nem logs de aplicação, permitem caracterizar os regimes normais de cada recurso de API e informar, no instante em que um incidente é aberto, se o recurso está em regime normal e, se não, qual indicador foi impactado (erros de negócio, erros de sistema ou latência) e desde quando. O método usa técnicas simples (mediana, MAD, percentis, validação cruzada e uma busca retroativa), não exige rótulos e produz uma explicação que um agente ou operador pode usar diretamente.

A informação é confiável quando emitida: 96,8% de especificidade, 96,4% de acerto no indicador e 92,9% de acerto na zona de início. A sensibilidade, porém, ainda é limitada (38%), sobretudo para latência e para erros de negócio em recursos com muitos 4xx naturais.

Como trabalhos futuros, destacam-se: (i) validar o método com incidentes reais, começando pelo evento observado no E02, e com a avaliação de operadores; (ii) usar um histórico maior, para capturar sazonalidades mensais; (iii) melhorar a sensibilidade à latência com percentis por requisição; (iv) avaliar a generalização para outras APIs; e (v) integrar a consulta como ferramenta de um agente de apoio a incidentes.

REFERÊNCIAS

Julien Audibert, Pietro Michiardi, Frédéric Guyard, Sébastien Marti, and Maria A. Zuluaga. 2020. USAD: UnSupervised Anomaly Detection on Multivariate Time Series. In *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining (KDD '20)*. ACM, New York.

Pete Chapman, Julian Clinton, Randy Kerber, Thomas Khabaza, Thomas Reinartz, Colin Shearer, and Rüdiger Wirth. 2000. *CRISP-DM 1.0: Step-by-Step Data Mining Guide*. Technical Report. SPSS.

Min Du, Feifei Li, Guineng Zheng, and Vivek Srikumar. 2017. DeepLog: Anomaly Detection and Diagnosis from System Logs through Deep Learning. In *Proceedings of the 2017 ACM SIGSAC Conference on Computer and Communications Security (CCS '17)*. ACM, New York, 1285–1298.

Olive Jean Dunn. 1961. Multiple Comparisons among Means. *J. Amer. Statist. Assoc.* 56, 293 (1961), 52–64.

William H. Kruskal and W. Allen Wallis. 1952. Use of Ranks in One-Criterion Variance Analysis. *J. Amer. Statist. Assoc.* 47, 260 (1952), 583–621.

Christophe Leys, Christophe Ley, Olivier Klein, Philippe Bernard, and Laurent Licata. 2013. Detecting Outliers: Do Not Use Standard Deviation Around the Mean, Use Absolute Deviation Around the Median. *Journal of Experimental Social Psychology* 49, 4 (2013), 764–766.

Stuart Lloyd. 1982. Least Squares Quantization in PCM. *IEEE Transactions on Information Theory* 28, 2 (1982), 129–137.

Yu Luo et al. 2025. OpsAgent: An Evolving Multi-Agent System for Incident Management in Microservices. arXiv:2510.24145. Acesso em: 18 maio 2026.

Quinn McNemar. 1947. Note on the Sampling Error of the Difference between Correlated Proportions or Percentages. *Psychometrika* 12, 2 (1947), 153–157.

Weibin Meng, Ying Liu, Yichen Zhu, Shenglin Zhang, Dan Pei, Yuqing Liu, Yihao Chen, Ruizhi Zhang, Shimin Tao, Pei Sun, and Rong Zhou. 2019. LogAnomaly: Unsupervised Detection of Sequential and Quantitative Anomalies in Unstructured Logs. In *Proceedings of the Twenty-Eighth International Joint Conference on Artificial Intelligence (IJCAI-19)*. IJCAI Organization, Macao, 4739–4745. https://doi.org/10.24963/ijcai.2019/658

Fabian Pedregosa, Gaël Varoquaux, Alexandre Gramfort, Vincent Michel, Bertrand Thirion, Olivier Grisel, Mathieu Blondel, Peter Prettenhofer, Ron Weiss, Vincent Dubourg, Jake Vanderplas, Alexandre Passos, David Cournapeau, Matthieu Brucher, Matthieu Perrot, and Édouard Duchesnay. 2011. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research* 12 (2011), 2825–2830.

Peter J. Rousseeuw. 1987. Silhouettes: A Graphical Aid to the Interpretation and Validation of Cluster Analysis. *J. Comput. Appl. Math.* 20 (1987), 53–65.

Alban Siffer, Pierre-Alain Fouque, Alexandre Termier, and Christine Largouet. 2017. Anomaly Detection in Streams with Extreme Value Theory. In *Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '17)*. ACM, New York, 1067–1075.

Gagan Somashekar, Anurag Dutt, Mainak Adak, Tania Lorido Botran, and Anshul Gandhi. 2024. GAMMA: Graph Neural Network-Based Multi-Bottleneck Localization for Microservices Applications. In *Proceedings of the ACM Web Conference 2024 (WWW '24)*. ACM, New York, 3085–3095.

Yuqing Wang, Mika V. Mäntylä, Serge Demeyer, Mutlu Beyazit, Joanna Kisaakye, and Jesse Nyyssölä. 2025. Cross-System Categorization of Abnormal Traces in Microservice-Based Systems via Meta-Learning. *Proceedings of the ACM on Software Engineering* 2, FSE (2025). Artigo FSE027.

Edwin B. Wilson. 1927. Probable Inference, the Law of Succession, and Statistical Inference. *J. Amer. Statist. Assoc.* 22, 158 (1927), 209–212.

Rüdiger Wirth and Jochen Hipp. 2000. CRISP-DM: Towards a Standard Process Model for Data Mining. In *Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining*. 29–39.

Zhaoyang Yu et al. 2025. Triangle: Empowering Incident Triage with Multi-Agent. In *Proceedings of the 40th IEEE/ACM International Conference on Automated Software Engineering (ASE 2025)*. IEEE/ACM. Disponível em: https://www.microsoft.com/en-us/research/wp-content/uploads/2025/02/TRIANGLE_ASE25.pdf. Acesso em: 18 maio 2026.

Chenxi Zhang, Xin Peng, Chaofeng Sha, Ke Zhang, Zhenqing Fu, Xiya Wu, Qingwei Lin, and Dongmei Zhang. 2022. DeepTraLog: Trace-Log Combined Microservice Anomaly Detection through Graph-Based Deep Learning. In *Proceedings of the 44th International Conference on Software Engineering (ICSE '22)*. ACM, New York, 623–634.

Wei Zhang et al. 2025. Intelligent Site Reliability Engineering: A Multi-Agent LLM Framework for Automated Incident Analysis and Root Cause Determination. https://www.researchgate.net/publication/399119176. Acesso em: 10 maio 2026.