Normalidade Contextual em APIs: Caracterização de Regimes a partir de Access Logs para Apoio à Análise de Incidentes

Diego Paz Casagrande
Universidade de Brasília
Brasília, DF, Brasil

RESUMO

Quando um incidente é aberto, uma das primeiras perguntas do operador é se as APIs envolvidas estão operando normalmente e, se não estão, qual indicador saiu do padrão. A resposta não é trivial, porque o comportamento de uma API varia legitimamente com o horário, o calendário e os processamentos em lote, e muda ao longo dos meses. Este trabalho investiga se *API Access Logs* (AALs) agregados por minuto permitem responder, no instante do registro do incidente, se cada recurso de API está em um de seus regimes normais (Normal) ou fora deles (Residual); qual indicador é responsável: erros de negócio (4xx), erros de sistema (5xx) ou latência; e desde quando. Seguindo o CRISP-DM, propõe-se um perfil de normalidade contextual por recurso (mediana e MAD por hora e tipo de dia), com um limite próprio para cada indicador calibrado por validação cruzada, e uma expansão retroativa em faixas de 15 min a 4 h para estimar o início do desvio. O estudo usa 14 recursos de produção com dados completos de junho a setembro de 2026 (24,5 milhões de registros e 3,5 bilhões de transações): o perfil é ajustado com junho a agosto e testado em 8.891 consultas simuladas em setembro. A decisão sobre os 15 minutos anteriores ao registro teve especificidade de 97,3%, sensibilidade de 63% (71% nas degradações de intensidade média e alta), indicador correto em 98,2% dos casos detectados e início dentro da zona estimada em 94,8% deles. Erros de sistema foram detectados em até 99% dos casos e a latência em 90% nas degradações de 10 vezes. Um histórico de 1 mês superou o de 3 meses, o que indica que o retreino frequente é preferível a um histórico longo.

PALAVRAS-CHAVE

Mineração de Dados; API Access Log; Normalidade Contextual; Análise de Incidentes; CRISP-DM; Regimes Operacionais.

1 INTRODUÇÃO

A arquitetura dos sistemas modernos consolidou o uso de APIs (*Application Programming Interfaces*) como mecanismo fundamental de integração em sistemas distribuídos. Em ambientes corporativos de grande porte, as APIs medeiam desde requisições de clientes externos até transações entre sistemas legados e modernos. No Banco do Brasil, cerca de 30 mil APIs são executadas diariamente, conectando soluções de negócio que combinam plataformas em nuvem e *mainframe*.

1.1 Contexto

Requisições processadas por gateways de API geram registros com o instante da execução, o recurso acessado, o código de resposta, o tempo de processamento e o consumidor. Neste estudo, esses registros são denominados *API Access Logs* (AALs): o registro gerado pelo gateway para as requisições processadas, distinto do *execution log* e do log de aplicação. Os AALs estão disponíveis de forma padronizada para um conjunto amplo de APIs, sem instrumentação específica no código.

O comportamento de uma API não é estacionário. Volume, latência e proporção de erros variam com o horário, o dia da semana, os processamentos em lote e as janelas de manutenção, e também mudam de patamar ao longo dos meses. Uma taxa de erros que é normal na virada do dia, durante um lote, pode ser anormal às 10h de um dia útil.

1.2 Problema

Quando um incidente é registrado, o operador precisa responder, para cada API envolvida: *no momento em que o incidente foi aberto, a API está operando dentro de um regime normal?* Se não está, importa saber *qual indicador foi impactado*: erros de negócio (faixa 4xx), erros de sistema (faixa 5xx) ou latência; e *desde quando* o desvio acontece. Como informação complementar, interessa saber se o impacto é *generalizado* ou concentrado em um *consumidor específico*, com volume suficiente para alterar o resultado agregado da API.

Hoje essa resposta depende de consultar várias ferramentas e de conhecer o comportamento típico de cada API [Zhang et al. 2025]. Limites fixos ou um único perfil de normalidade não distinguem a variação legítima (um lote à meia-noite, o volume menor no fim de semana) de um desvio real.

Do ponto de vista de mineração de dados, o problema consiste em: (1) caracterizar os regimes normais de cada recurso a partir de AALs agregados; (2) classificar o período imediatamente anterior ao registro de um incidente em dois estados: Normal (dentro de algum regime normal esperado para aquele contexto) ou Residual (todo o resto); e (3) quando Residual, identificar o indicador responsável e o início do desvio.

1.3 Motivação

Este trabalho complementa um projeto de mestrado sobre sistemas multiagente para apoio ao atendimento de incidentes. A literatura recente mostra agentes especializados em diferentes fontes de dados, coordenados para triagem e análise [Luo et al. 2025; Yu et al. 2025; Zhang et al. 2025]. Um desses agentes precisa de uma fonte confiável e explicável sobre o comportamento das APIs. O foco não é monitoração em tempo real nem a identificação da causa raiz, mas a *informação de contexto no instante do incidente*: dizer se cada recurso está em regime normal e, se não, qual indicador está impactado e desde quando. Essa informação abastece o operador e colabora para a análise do ocorrido.

1.4 Objetivos

Objetivo geral: caracterizar os regimes normais de cada recurso de API a partir de Access Logs agregados e, no instante do registro de um incidente, informar se o recurso está em regime normal e, se não, qual indicador foi impactado e desde quando.

Objetivos específicos:

- Verificar se cada recurso apresenta vários regimes normais ligados ao contexto (hora e tipo de dia).
- Construir um perfil de normalidade por recurso e contexto e uma regra de decisão Normal/Residual explicável.
- Identificar o indicador responsável (4xx, 5xx, latência) e estimar o início do desvio.
- Avaliar o método em cenários de incidente simulados e compará-lo a baselines simples.
- Avaliar quanto histórico o perfil precisa (3 meses ou 1 mês).
- Disponibilizar a informação em formato estruturado para um agente ou operador.

1.5 Questões de pesquisa

- **RQ1.** AALs agregados permitem caracterizar os regimes normais de cada recurso e decidir, no instante do registro, se o recurso está em regime normal?
- **RQ2.** Quando o recurso não está em regime normal, o método identifica corretamente o indicador responsável (4xx, 5xx, latência) e o início do desvio?
- **RQ3.** Qual o período anterior ao registro (15, 30 ou 60 min) mais adequado para a decisão, e como o intervalo entre o início da degradação e o registro afeta o resultado?
- **RQ4.** Um histórico mais longo (3 meses) produz um perfil melhor do que o histórico recente (1 mês)?

1.6 Contribuições e organização

As contribuições são: (i) a caracterização empírica dos regimes de 14 recursos de API de produção de alto volume; (ii) um método simples e explicável, sem rótulos, que decide o estado de um recurso no instante do registro e aponta o indicador impactado; (iii) uma estimativa de início por expansão retroativa; (iv) um protocolo de avaliação com cenários de incidente simulados; e (v) evidência de que o histórico recente é mais útil que o longo. A Seção 2 discute os trabalhos correlatos; a Seção 3, a metodologia; a Seção 4, os resultados; a Seção 5, a discussão; a Seção 6, as ameaças à validade; e a Seção 7 conclui.

2 TRABALHOS CORRELATOS

2.1 Análise e mineração de logs

Du et al. [2017] propuseram o DeepLog, que emprega redes LSTM para aprender sequências normais de eventos de log e sinalizar desvios. Meng et al. [2019] propuseram o LogAnomaly, que combina informação semântica dos *templates* com a detecção de anomalias sequenciais e quantitativas. Ambos mostram que logs carregam informação suficiente para caracterizar comportamento, mas operam sobre sequências de eventos de logs de sistema, e não sobre AALs agregados; tampouco tratam da coexistência de múltiplos regimes normais.

2.2 Normalidade e séries temporais

Siffer et al. [2017] propuseram o SPOT/DSPOT, que calibra limiares a partir da cauda da distribuição com Teoria de Valores Extremos e os adapta a séries não estacionárias, mas sem identificar os contextos que fazem o limiar variar. Audibert et al. [2020] propuseram o USAD, baseado em autoencoders para séries multivariadas, centrado em escores de anomalia, e não na interpretação de regimes. Wang et al. [2025] discutem a dificuldade de generalizar modelos entre sistemas distintos, o que reforça a opção por perfis ajustados por recurso.

2.3 Modelagem comportamental de microsserviços

O DeepTraLog [Zhang et al. 2022] combina *traces* e logs em grafos, e o GAMMA [Somashekar et al. 2024] localiza gargalos com redes neurais em grafos. Esses trabalhos pressupõem *traces*, logs internos ou métricas de infraestrutura, que extrapolam o AAL isolado.

2.4 Incidentes e sistemas multiagente

O Triangle [Yu et al. 2025] usa múltiplos agentes na triagem de incidentes; o OpsAgent [Luo et al. 2025] e o trabalho de Zhang et al. [2025] coordenam agentes especializados para análise de incidentes. Esses sistemas dependem de fontes que resumam o estado dos componentes de forma confiável. O presente trabalho se posiciona como uma dessas fontes: transforma AALs em evidência explicável sobre o estado de cada recurso no momento do incidente.

2.5 Síntese e lacuna

Os trabalhos revisados tratam o comportamento, predominantemente, a partir de um único perfil de normalidade; dependem de fontes além do AAL; ou focam na causa raiz. Nenhum investiga, a partir exclusivamente do AAL, a caracterização de múltiplos regimes normais por recurso e o seu uso para informar, no instante de um incidente, o estado do recurso, o indicador impactado e o início do desvio.

3 METODOLOGIA

O trabalho segue o CRISP-DM [Chapman et al. 2000; Wirth and Hipp 2000]. Cada fase foi implementada em um *notebook* Jupyter com parâmetros explícitos e sementes fixas (Tabela 1). A análise é sempre *por recurso*. Optou-se por técnicas simples de explicar: seis no total, todas disponíveis em pandas, SciPy e scikit-learn [Pedregosa et al. 2011].

3.1 Entendimento do negócio

A decisão apoiada é: *no instante do registro do incidente, o recurso está em regime normal? Se não, qual indicador foi impactado (erros 4xx, erros 5xx, latência) e desde quando?* A abrangência (consumidor específico ou generalizado) é informação complementar. Os critérios de sucesso foram definidos antes da modelagem (Tabela 7). Como não havia histórico de incidentes, a avaliação usa cenários simulados com falhas injetadas.

Tabela 1: Fases do CRISP-DM, notebooks e técnicas.

Fase	Notebook: conteúdo (técnica)
Negócio, Dados	01: problema, critérios de sucesso, extração e seleção dos recursos, qualidade e evolução mensal
Preparação	02: consolidação, atributos por janela, p95 de latência
Dados, Modelagem	03: regimes (Kruskal-Wallis; k-means)
Modelagem	04: perfil contextual (mediana/MAD); limite por indicador (validação cruzada), por histórico
Preparação	05: cenários de incidente (injeção de falhas)
Avaliação	06: estado, indicador, início (expansão retroativa); histórico; IC de Wilson, McNemar
Implantação	07: consulta estruturada para o agente

3.2 Entendimento dos dados

A base original tem 118 milhões de linhas de AALs de produção de 18 recursos (`CD_RCS_CAT`), de maio a setembro de 2026. **Cada linha é um agregado por minuto × recurso × código HTTP × cliente**: o total de execuções no minuto (`QT_TTL_TRAN`) e o tempo médio dessas execuções (`QT_TMP_MEDI_EXEA`). Não há registros por requisição. O identificador de cliente foi anonimizado por SHA-256 com semente, sem payloads nem dados pessoais. Os horários, em UTC, foram convertidos para o horário de Brasília (UTC−3) antes de qualquer corte temporal.

Seleção dos recursos. Foram mantidos apenas os recursos com dados em *todos os dias* de 01/06 a 20/09 (horário de Brasília): 14 dos 18, identificados aqui por A01 a A14 em ordem decrescente de volume. Os quatro descartados, com 7 a 16 dias sem dados, somavam 21% do volume do período.

O recorte tem 24.495.617 linhas, 3,5 bilhões de transações e 5.506 clientes, de 01/06/2026 a 20/09/2026 20h59. As respostas 2xx somam 94,1% das transações; 4xx, 5,8%; 5xx, 0,09%. Há 375.697 linhas excedentes com a mesma chave (minuto, recurso, código, cliente), que concentram 7,5% do volume. Os recursos são de alto volume: a mediana de transações por 15 min vai de 453 (A14) a 85.335 (A01). O A08 atende 5.390 clientes; o A12, apenas 4. Dois recursos (A05 e A06) têm dados em todos os dias, mas não em todos os minutos (72% e 77% dos minutos).

Evolução mensal. O volume dos maiores recursos é estável entre junho e setembro, mas alguns mudam de patamar: o A13 cai de 272 mil para 53 mil transações por dia; a taxa de erros de negócio do A08 passa de 8% (junho) para 45% (setembro), e a do A07, de 8,5% para 0,7%. Essa mudança motiva a questão RQ4.

3.3 Preparação dos dados

As chaves repetidas foram consolidadas (soma do volume e média de latência ponderada). Os registros foram agregados em janelas de 1 h (37.586 janelas recurso × hora) e em períodos de 15 e 30 min. A decisão usa quatro indicadores (Tabela 2). O *contexto* de cada período é o par (tipo de dia, hora), com tipo de dia *útil* ou *não útil* (sábado, domingo e feriados: 04/06 e 07/09).

Latência p95. Como não há latência por requisição, o p95 é o percentil 95 das latências médias por minuto × cliente das respostas 2xx, ponderado pelo número de execuções. É um p95 *das médias*, não das requisições, e tende a subestimar a cauda real; mas é consistente entre períodos e sensível a degradações que atingem só parte dos minutos ou dos consumidores. Na mediana, ele é 1,21 vez a latência média.

Tabela 2: Indicadores usados na decisão e direção desfavorável.

Indicador	Definição	Direção
volume	log(1+transações), na escala horária	alta e queda
erros 4xx	transações 4xx / total (erros de negócio)	alta
erros 5xx	transações 5xx / total (erros de sistema)	alta
latência p95	log(1+p95 das médias por minuto×cliente)	alta

3.4 Modelagem

Regimes (descritivo). O teste de Kruskal-Wallis [Kruskal and Wallis 1952], com correção de Bonferroni [Dunn 1961], verifica se cada indicador muda entre as 24 horas dos dias úteis. Para cada recurso, o k-means [Lloyd 1982] agrupa as janelas de 1 h de junho a agosto usando apenas os indicadores padronizados e limitados aos percentis 1 e 99 do recurso, para que picos isolados não formem grupos próprios. O número de regimes, $k \in [2, 8]$, é escolhido pelo coeficiente de silhouette [Rousseeuw 1987]. O contexto não entra no agrupamento; ele é usado depois, para nomear cada regime (nível de volume, tipo de dia e horas em que predomina). O k-means é descritivo: a decisão usa o perfil contextual.

Perfil de normalidade contextual. Para o recurso r, o contexto c e o indicador a, o perfil guarda a mediana $m_a(r, c)$ e a escala robusta [Leys et al. 2013]

$$s_a(r, c) = \max\{1{,}4826 \cdot \mathrm{MAD}_a(r, c),\ \varepsilon_a\}, \tag{1}$$

calculadas nas janelas de 1 h do histórico, em que ε_a é um piso que evita divisões por valores próximos de zero. Para um período w, o desvio de cada indicador, contado só na direção desfavorável, é

$$z_a(w) = \frac{x_a(w) - m_a(r, c)}{s_a(r, c)}, \tag{2}$$

$$d_a(w) = \begin{cases} |z_a(w)| & \text{volume,} \\ \max\{z_a(w), 0\} & \text{demais indicadores.} \end{cases} \tag{3}$$

Períodos de 15 e 30 min usam o mesmo perfil de 1 h: o volume é convertido para a escala horária, e as taxas e o p95 são usados diretamente.

Limite por indicador. Os indicadores têm variabilidades muito diferentes; em alguns recursos a taxa de 4xx tem picos reais frequentes. Por isso, cada indicador tem um limite próprio no recurso, $L_{r,a} = \max\{3,\ Q_{0,99}(d_a)\}$: o percentil 99 dos seus desvios no histórico, calculados fora da amostra. O limite é recalculado para cada tamanho de período (15, 30 e 60 min), porque períodos curtos variam mais. O período é Residual se algum indicador passa do seu limite ($d_a / L_{r,a} > 1$); o **indicador responsável** é o que mais passou, em múltiplos do limite.

Tabela 3: Motivos injetados.

Motivo	Intensidade (baixa / média / alta / muito alta)
4xx generalizado	5% / 15% / 40% das 2xx viram 400
4xx de 1 consumidor	30% / 60% / 90% das 2xx do consumidor viram 400
5xx generalizado	5% / 15% / 40% das 2xx viram 503
5xx de 1 consumidor	30% / 60% / 90% das 2xx do consumidor viram 503
Latência	tempo de execução ×1,5 / ×2,5 / ×4 / ×10

O consumidor afetado é sorteado com probabilidade proporcional ao seu volume.

Histórico e calibração sem vazamento. O teste é em 01 a 20/09. O perfil e os limites são ajustados só com dados anteriores, em dois históricos: *3 meses* (principal; junho a agosto) e *1 mês* (agosto). Os desvios fora da amostra vêm de validação cruzada com quatro blocos contíguos de tempo dentro do histórico: o perfil é ajustado em três blocos e avalia o restante. Com essa regra, cerca de 3% dos períodos do histórico são Residual.

Início estimado (expansão retroativa). A partir do registro, o método avalia faixas disjuntas cada vez mais distantes: 0–15, 15–30, 30–60 min e, depois, de hora em hora até 4 h, cada uma com o limite do seu tamanho. A busca para na primeira faixa Normal, e o início é estimado entre o começo da última faixa residual e o fim dessa faixa normal.

Abrangência (complementar). Para erros 4xx ou 5xx, o desvio é atribuído a um *consumidor específico* quando o cliente com mais erros concentra ao menos 80% deles e essa fatia supera em pelo menos 20 pontos percentuais a sua fatia do volume; caso contrário, é *generalizado*. Períodos com menos de três clientes ativos ficam indeterminados.

3.5 Avaliação

Cenários de incidente. Cada cenário simula um incidente: uma degradação começa em t_0 e o incidente é registrado em $t = t_0 + \Delta$, com atraso $\Delta \in \{15, 30, 60, 120\}$ min. O instante de registro é sorteado entre 01/09 às 04h e 20/09 às 21h. As falhas (Tabela 3) são aplicadas nos registros por minuto × cliente e depois reagregadas, para que os indicadores e a abrangência reajam como numa falha real. Foram gerados 5 cenários por recurso × motivo × intensidade × atraso (4.480 incidentes) e 4.480 consultas de controle, em instantes sem falha injetada. Sessenta e nove incidentes caíram em intervalos sem nenhum tráfego no recurso (sobretudo nos recursos com minutos sem dados), onde a falha não se manifesta, e foram excluídos: restam 4.411 incidentes e 4.480 controles.

Latência ×10. Como a latência vem de médias por minuto, poucas requisições lentas elevam muito o valor. No histórico, o p95 horário ultrapassou 10 vezes a mediana do seu contexto em 0,13% das horas (percentil 99,9: 15 vezes; máximo: 59 vezes). Degradações de latência relevantes para um incidente podem ser desse tamanho, por isso a intensidade "muito alta" (×10) foi incluída. As intensidades menores foram mantidas para mostrar o limite do método.

Métricas. Para cada cenário, avalia-se o período $[t - L, t)$, com $L = 15$ min como principal e 30 e 60 min para comparação. As métricas são: *sensibilidade* (incidentes com saída Residual); *especificidade* (controles com saída Normal); *acurácia do indicador* (indicador apontado igual ao do motivo injetado, entre os detectados); *acerto do início* (início real dentro da zona estimada); e *acurácia da abrangência*. "Média/alta" refere-se às intensidades média e alta, sem a latência ×10. As proporções têm intervalos de confiança de Wilson a 95% [Wilson 1927].

Baselines. Com o mesmo tratamento de limites e calibração: (i) *z-score global*, o mesmo perfil sem contexto (um por recurso); e (ii) *semana anterior*, que compara com o mesmo período sete dias antes. A comparação usa o teste exato de McNemar [McNemar 1947] sobre os acertos de estado nos mesmos cenários; o mesmo teste compara os históricos de 3 meses e de 1 mês.

4 RESULTADOS

4.1 Regimes normais por recurso (RQ1)

A Figura 1 mostra os quatro recursos com padrão horário mais marcado: lotes na madrugada (A05 às 2–3h; A09 à 0–1h e às 11h), lote na virada do dia e às 18h dos dias úteis (A10) e padrão comercial com menor volume em dias não úteis (A12). A Figura 2 mostra que cada recurso tem sua própria assinatura horária de volume e de latência. Nos dias úteis, 93% dos testes de Kruskal-Wallis (recurso × indicador) foram significativos após Bonferroni. O efeito mediano (ε^2) foi grande para volume (0,56), latência p95 (0,43), erros 4xx (0,25) e erros 5xx (0,21). A exceção é o A13, que só tem um indicador com variação horária significativa.

O k-means encontrou de 2 a 6 regimes por recurso (mediana 3; silhouette médio 0,54; Tabela 4). A Figura 3 ilustra o A11: um regime de volume alto na madrugada (0–8h nos dias úteis, 0–6h nos não úteis) e um de volume baixo no restante do dia. É o tipo de variação legítima que um limite fixo trataria como anomalia em um dos dois períodos.

4.2 Limites por indicador

Os limites (Figura 4) variam de 3 a 100 em z. Limites altos revelam indicadores com picos reais frequentes no histórico: erros 4xx em A06 (100), A05 (50), A08 (45) e A07 (42); volume em A05 (72), A13 (32) e A06 (29); e latência p95 em A02 (21). Nesses casos, só desvios grandes daquele indicador são marcados como Residual. No histórico de junho a agosto, fora da amostra, 3,2% das janelas de 1 h foram residuais, com latência (300 janelas), erros 4xx (290), volume (280) e erros 5xx (129) como indicadores responsáveis.

4.3 Estado no instante do registro (RQ1)

A Tabela 5 e a Figura 5 resumem a decisão. Com a faixa de 15 min, o perfil contextual classificou corretamente 97,3% dos controles como Normal e sinalizou como Residual 63,0% dos incidentes (70,6% nas intensidades média e alta). Nos acertos de estado, ele supera o z-score global nas faixas de 15 e 30 min (McNemar: $p = 0{,}009$ e $p = 0{,}046$) e empata com a semana anterior em todas as faixas ($p \geq 0{,}48$).

Ponto de operação. O limite de cada indicador é o seu percentil 99 no histórico (multiplicador $c = 1$), ponto escolhido em versão anterior do estudo porque a consulta só é feita quando já existe um incidente aberto. A Figura 6 mostra também os pontos com 1% e

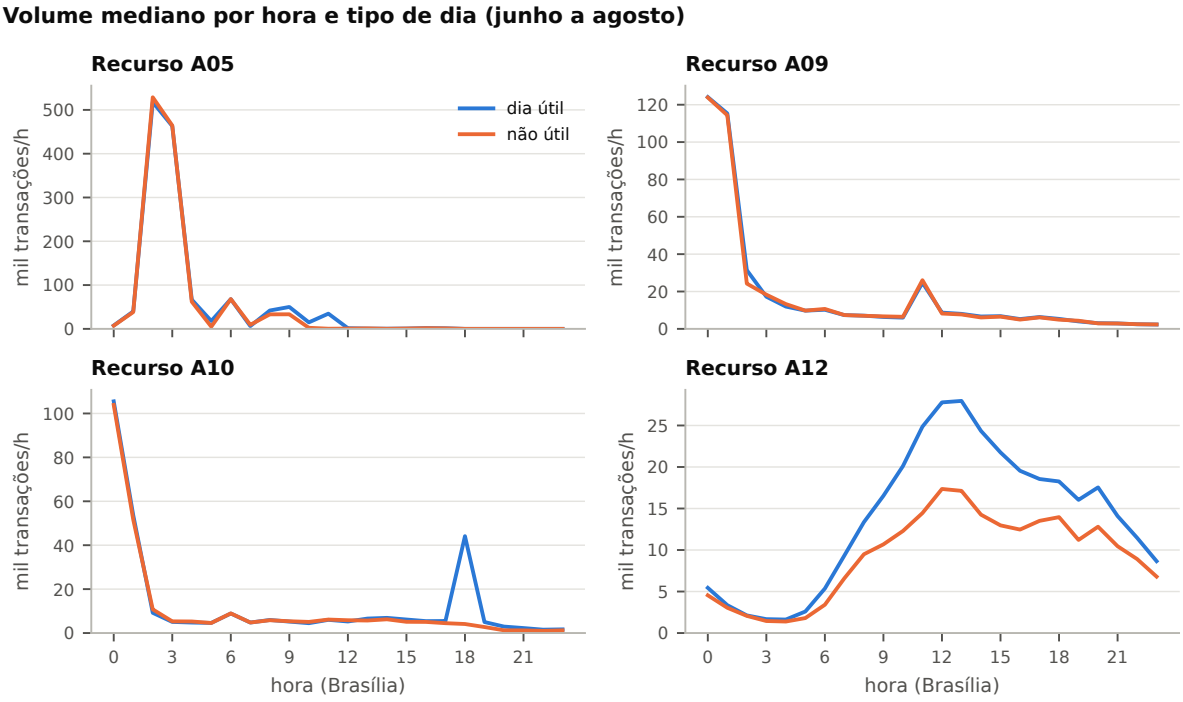


Figura 1: Volume mediano por hora e tipo de dia (junho a agosto), nos quatro recursos com padrão horário mais marcado.

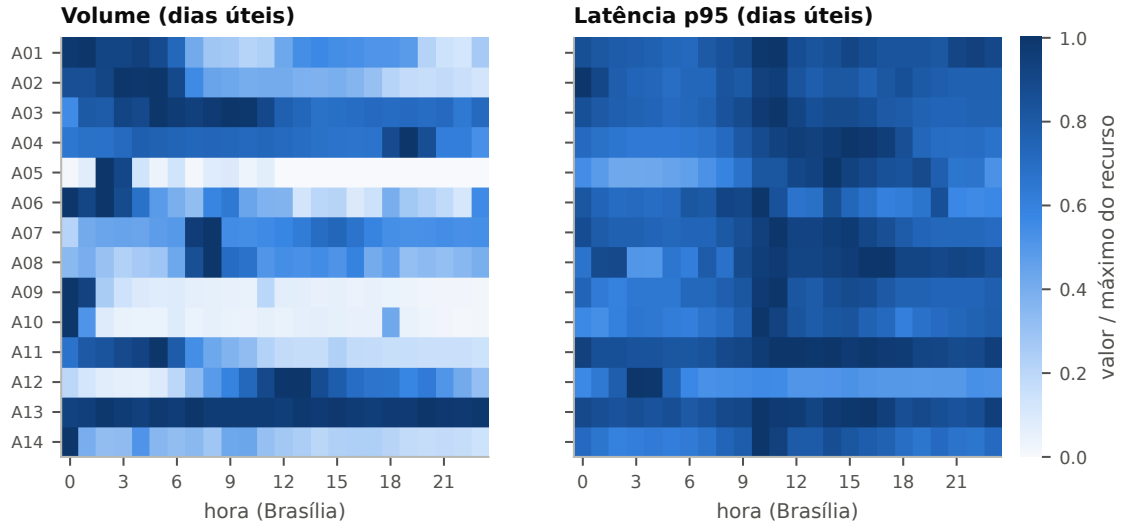


Figura 2: Volume e latência p95 medianos por hora em dias úteis, normalizados pelo máximo de cada recurso.

2% de alarmes no histórico. Nesses pontos mais conservadores, o z-score global detecta um pouco mais que o perfil contextual; no ponto adotado, o perfil contextual detecta mais, com 0,7 a 0,9 ponto a mais de falsos RESIDUAL.

Por motivo. A sensibilidade depende do motivo (Figura 7). Erros de sistema generalizados são detectados em 72% a 99% dos casos, conforme a intensidade, e erros 5xx de um consumidor em 74% a 84%. Erros de negócio têm detecção de 17% a 66% (generalizados) e de 36% a 62% (um consumidor). A latência vai de 13% (×1,5) a 72% (×4) e chega a **90%** [86; 93] na degradação de 10 vezes.

Por recurso e ao longo do teste. Por recurso (Tabela 4), a sensibilidade vai de 26% (A06, com limites de 4xx e 5xx muito altos e

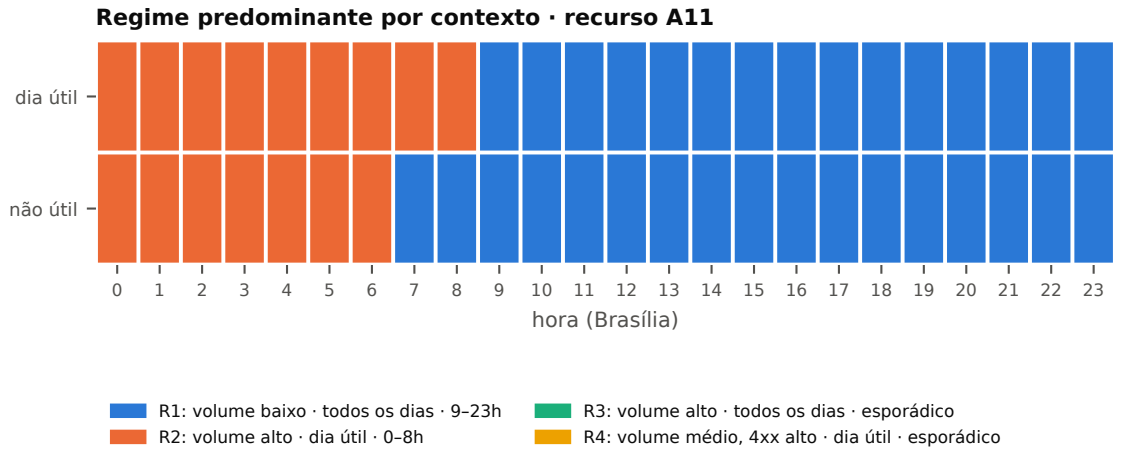


Figura 3: Regime predominante (k-means com os indicadores) por tipo de dia e hora no recurso A11.

Tabela 4: Resumo por recurso: participação no volume, clientes, transações medianas por 15 min, regimes e resultados no registro (faixa de 15 min, histórico de 3 meses).

Recurso	Vol. (%)	Clientes	Trans./15 min	Regimes (k)	Silhouette	Sensib.	Sensib. média/alta	Especif.	Acurácia indicador
A01	27,6	36	85.335	2	0,75	0,72	0,79	0,96	0,99
A02	26,0	45	67.001	2	0,66	0,66	0,75	0,97	0,99
A03	13,4	46	42.997	2	0,49	0,85	0,95	0,98	0,98
A04	11,1	45	34.148	2	0,69	0,87	0,92	0,99	0,99
A05	5,5	43	1.906	6	0,49	0,57	0,62	0,95	0,94
A06	5,3	21	14.840	6	0,57	0,26	0,27	1,00	1,00
A07	4,4	29	11.647	2	0,70	0,64	0,72	0,99	1,00
A08	1,5	5.390	3.999	2	0,47	0,39	0,47	0,93	0,95
A09	1,5	35	1.617	5	0,41	0,74	0,84	0,96	0,98
A10	1,1	37	1.240	5	0,39	0,58	0,63	0,96	0,96
A11	1,0	37	1.971	4	0,42	0,70	0,80	0,96	0,97
A12	1,0	4	2.843	2	0,43	0,63	0,75	0,99	0,99
A13	0,4	46	827	6	0,65	0,70	0,80	1,00	1,00
A14	0,2	37	453	5	0,42	0,48	0,50	0,98	0,99

Tabela 5: Estado no registro por método e faixa anterior ao registro, em % (IC de Wilson a 95% entre colchetes). Histórico de 3 meses; 4.411 incidentes e 4.480 controles.

Método	Faixa L	Sensibilidade	Sensibilidade (média/alta)	Especificidade
Perfil contextual (proposto)	15 min	**63,0** [61,6; 64,4]	**70,6** [68,8; 72,2]	97,3 [96,7; 97,7]
	30 min	60,3 [58,8; 61,7]	68,3 [66,5; 70,0]	97,2 [96,6; 97,6]
	60 min	56,4 [55,0; 57,9]	64,9 [63,1; 66,7]	96,9 [96,3; 97,4]
z-score global	15 min	61,0 [59,6; 62,4]	68,8 [67,0; 70,5]	98,0 [97,6; 98,4]
	30 min	58,3 [56,8; 59,7]	66,3 [64,5; 68,0]	98,2 [97,7; 98,5]
	60 min	54,5 [53,0; 55,9]	62,5 [60,7; 64,3]	98,4 [98,0; 98,7]
Semana anterior	15 min	62,0 [60,6; 63,4]	70,4 [68,6; 72,1]	98,2 [97,8; 98,6]
	30 min	59,6 [58,1; 61,0]	68,3 [66,6; 70,1]	98,2 [97,8; 98,6]
	60 min	55,3 [53,8; 56,8]	64,1 [62,3; 65,9]	98,3 [97,9; 98,6]

23% dos minutos sem dados) a 87% (A04). Os quatro maiores recursos (A01 a A04) ficam entre 66% e 87%. O resultado é estável ao longo de setembro: 63,3%, 60,6% e 65,3% de sensibilidade nas três semanas, com especificidade entre 95,5% e 98,6%.

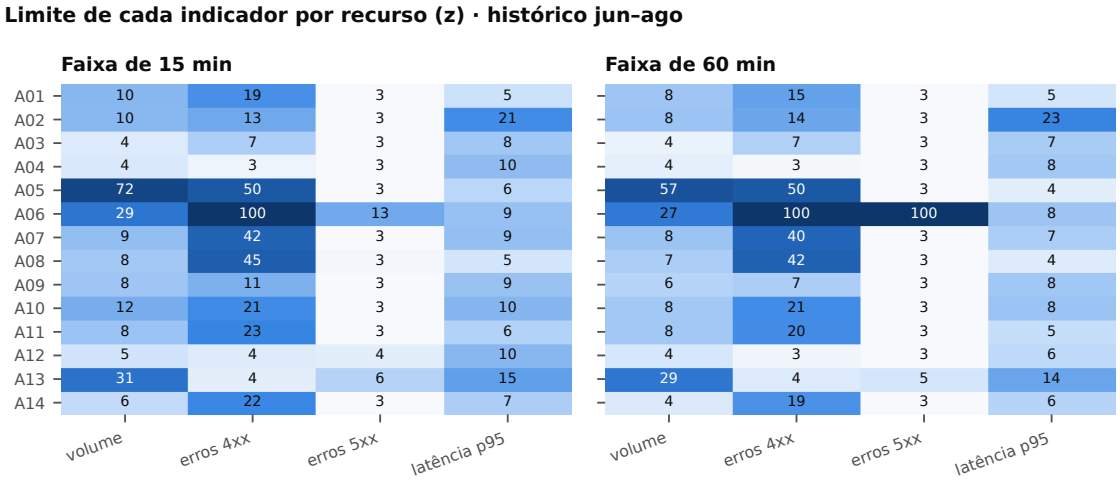


Figura 4: Limite de cada indicador por recurso (z, percentil 99 fora da amostra, mínimo 3), para períodos de 15 e de 60 min; histórico de junho a agosto.

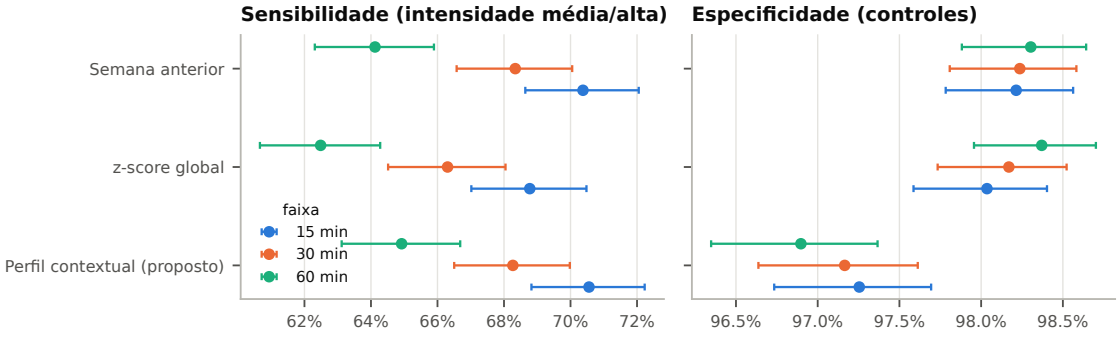


Figura 5: Sensibilidade (intensidades média e alta) e especificidade por método e faixa, com IC de Wilson a 95%.

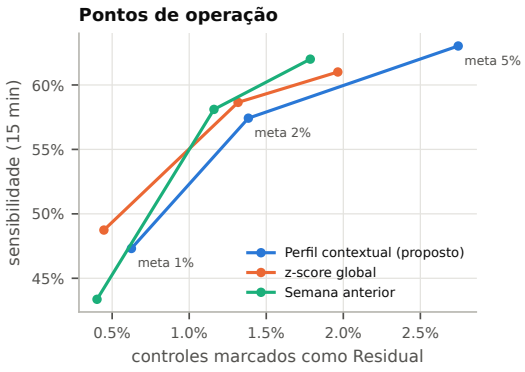


Figura 6: Sensibilidade contra controles marcados como Residual (faixa de 15 min), para metas de 1%, 2% e 5% de alarmes no histórico.

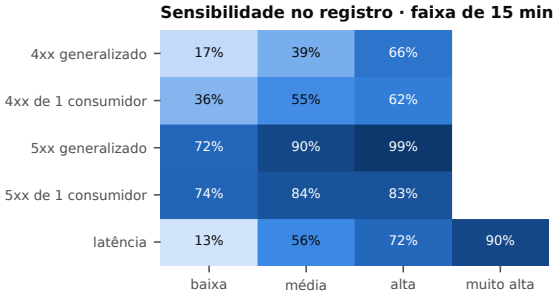


Figura 7: Sensibilidade no registro (faixa de 15 min) por motivo e intensidade.

4.4 Tamanho da faixa e atraso do registro (RQ3)

A faixa mais curta é a melhor quando o incidente é registrado logo após o início da degradação (Figura 8): com atraso de 15 min, a sensibilidade (intensidades média e alta) é de 74% com a faixa de

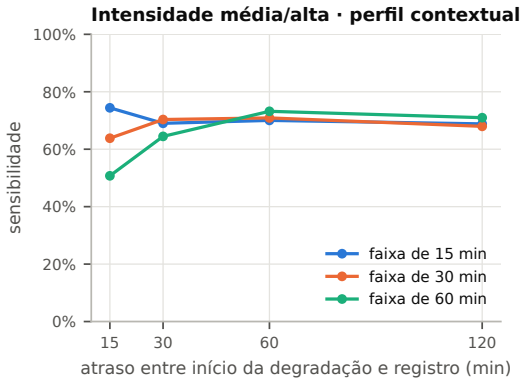


Figura 8: Sensibilidade (intensidades média e alta) por atraso entre o início da degradação e o registro, para cada tamanho de faixa.

Tabela 6: Histórico de 3 meses × 1 mês (proposto, faixa de 15 min, em %; m/a = intensidades média e alta).

Histórico	Sensib.	Sensib. m/a	Especif.	Acur. indicador
3 meses	63,0	70,6	97,3	98,2
1 mês	67,0	72,9	96,6	98,5

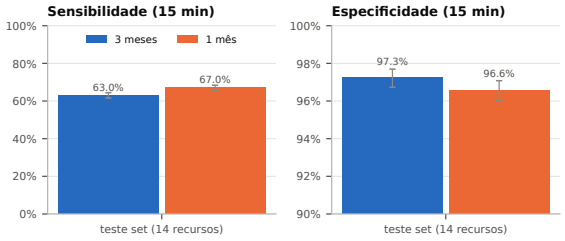


Figura 9: Sensibilidade e especificidade (faixa de 15 min) por histórico, com IC de Wilson a 95%.

15 min, contra 51% com a de 60 min, que mistura minutos normais e degradados. Com atraso de 60 ou 120 min, a faixa de 60 min fica ligeiramente melhor (71–73% contra 69–70%). Na média, a faixa de 15 min é a melhor.

4.5 Histórico de 3 meses × 1 mês (RQ4)

O histórico mais longo *não* melhorou o resultado (Tabela 6, Figura 9). Com 1 mês, a sensibilidade subiu de 63,0% para 67,0% e a especificidade caiu de 97,3% para 96,6%; nos acertos de estado, o histórico de 1 mês foi melhor em todas as faixas (McNemar: $p < 10^{-7}$). Os limites refletem a diferença: com 3 meses, o limite de erros 4xx fica, na mediana, 32% maior, e chega a ser 14 vezes maior no A07 e 6 vezes maior no A01, recursos cuja taxa de 4xx caiu de junho para agosto.

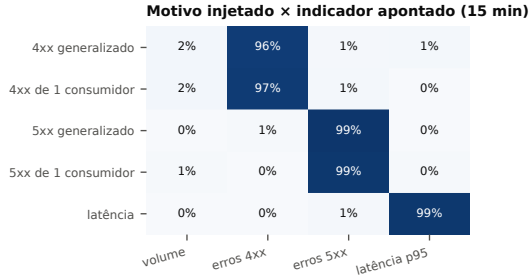


Figura 10: Motivo injetado contra indicador apontado (faixa de 15 min, casos detectados).

4.6 Indicador responsável e início (RQ2)

Quando o recurso é sinalizado como Residual, o indicador apontado é o do motivo injetado em 98,2% dos casos [97,6; 98,6] (Figura 10): 99,3% para 5xx generalizado, 98,6% para 5xx de um consumidor e para latência, e 96–97% para 4xx.

A expansão retroativa (Figura 11) colocou o início real dentro da zona estimada em 94,8% dos casos detectados [93,9; 95,6]: 98% quando a degradação começou 15 ou 30 min antes do registro, 94% com 60 min e 89% com 120 min (Figura 12). Os erros são quase sempre subestimações: uma faixa intermediária sai Normal, a busca para cedo e o início é estimado mais perto do registro do que de fato ocorreu.

Abrangência (complementar). Entre os erros 4xx e 5xx detectados com o indicador correto, a abrangência foi classificada corretamente em 71,6% [69,6; 73,4]. Os erros generalizados são reconhecidos como tais em 77–85% dos casos; os de um consumidor, em 58% (4xx) e 63% (5xx). Uma parte relevante (14–26%) fica indeterminada, porque nesses recursos há períodos de 15 min com menos de três clientes ativos.

4.7 Saída para o agente e evento real

A consulta produz um documento estruturado. A Figura 13 mostra, resumida, a saída do cenário da Figura 11.

Nos dados reais, sem injeção, a primeira consulta de controle marcada como Residual foi a do A12 às 22h46 de 11/09: latência p95 de 456 ms nos 15 min anteriores, com faixa normal de 123 a 149 ms para aquele contexto (1,77 vez o limite), e início estimado entre 0 e 30 min antes. É um candidato a degradação real de latência, a confirmar com a operação.

4.8 Critérios de sucesso

Os cinco critérios definidos antes da modelagem foram atendidos (Tabela 7), a sensibilidade por margem estreita.

5 DISCUSSÃO

RQ1: regimes e estado no registro. Os AALs agregados mostram regimes claros e ligados ao contexto, sobretudo à hora: lotes na madrugada, horário comercial e padrões diferentes em dias não úteis. O perfil contextual decide o estado de cada recurso no momento do incidente com alta especificidade (97,3%) e sensibilidade de 63%

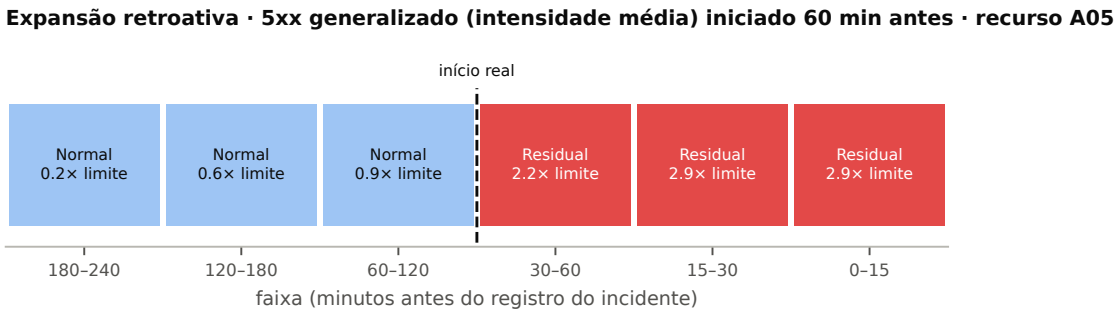


Figura 11: Expansão retroativa em um cenário de 5xx generalizado iniciado 60 min antes do registro (A05): as três faixas mais recentes são residuais e a de 60–120 min é normal, e o início é estimado entre 30 e 120 min antes.

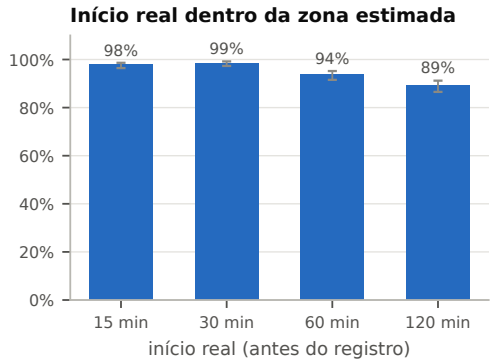


Figura 12: Início real dentro da zona estimada, por atraso (IC de Wilson a 95%).


```
{"recurso": "A05", "registro_incidente": "2026-09-19 12:28",
 "contexto": {"tipo_dia": "não útil", "hora": "12h"},
 "estado": "Residual", "indicador_impactado": "erros 5xx",
 "evidencias": [{"indicador": "erros 5xx", "observado": "8.7%",
    "faixa_normal_p5_p95": ["0.0%", "0.0%"], "vezes_o_limite": 2.91}],
 "inicio_estimado": "entre 30 e 120 min antes do registro",
 "abrangencia": {"classificacao": "generalizado",
    "clientes_ativos": 4, "clientes_com_erro": 3},
 "motivo_estatistico": "O recurso A05 está fora do regime normal
   esperado para não útil às 12h. Indicador impactado: erros 5xx
   − 8.7% nos 15 min anteriores ao registro (faixa normal 0.0% a
   0.0%), 2.91× o limite do recurso. O desvio começou entre 30 e
   120 min antes do registro. Os erros aparecem em 3 de 4
   consumidores ativos."}
```


Figura 13: Saída da consulta para o agente (resumida).

(71% para degradações médias e altas). Em relação ao z-score global, o ganho é pequeno mas significativo; em relação à semana anterior, há empate. Além da detecção, o contexto dá a *explicação*: a faixa normal do contexto, o regime esperado e o limite de cada indicador permitem dizer ao operador "8,7% de 5xx ao meio-dia de um sábado, quando o normal é zero". Para o operador, um resultado Residual é informação forte (raramente aparece sem motivo, e vem com o indicador certo); um resultado Normal indica que o recurso dificilmente é a origem, mas não descarta degradações sutis.

Tabela 7: Critérios de sucesso (faixa de 15 min, histórico de 3 meses).

Critério	Resultado	Atendido
Controles com saída Normal ≥ 95%	97,3%	sim
Sensibilidade (média/alta) ≥ 70%	70,6%	sim
Acurácia do indicador ≥ 90%	98,2%	sim
Início real na zona estimada ≥ 70%	94,8%	sim
Sem perda significativa para os baselines	sem perda	sim

O efeito do volume. Os resultados desta versão são bem melhores que os obtidos com recursos de menor volume em versões anteriores do estudo (sensibilidade de 39% e 43% nas intensidades média e alta). Com dezenas de milhares de transações por 15 min, as taxas de erro e o p95 variam menos dentro de cada contexto, os limites ficam mais estreitos e as degradações aparecem com mais clareza. Os quatro maiores recursos (A01 a A04) têm sensibilidade de 66% a 87%. Isso sugere que o método é mais útil justamente nas APIs de maior volume, que tendem a ser as mais críticas.

RQ2: indicador e início. O ponto mais forte do método é a qualidade da informação quando ela é emitida: o indicador responsável é apontado corretamente em 98% dos casos, e o início é localizado na zona certa em 95%. A expansão retroativa é simples de explicar ("olhar para trás até encontrar um período normal") e dá ao operador uma resposta útil em faixas de 15 min a 1 h, que é a escala em que incidentes costumam ser abertos.

RQ3: tamanho da faixa. A faixa de 15 min é a melhor escolha como decisão principal, porque o incidente costuma ser aberto pouco depois do início da degradação. Faixas maiores só compensam quando a degradação já dura uma hora ou mais. Na prática, a faixa curta decide o estado e a expansão retroativa dá o horizonte.

RQ4: quanto histórico. Pela segunda vez no estudo, e agora com outro conjunto de recursos, mais histórico não significou um perfil melhor. As APIs mudam de patamar ao longo dos meses, e um histórico de três meses inclui comportamentos que já não valem (por exemplo, taxas de erros de negócio que depois caíram), o que

alarga os limites. Para a implantação, isso favorece o *retreino frequente com o histórico recente* (por exemplo, mensal com o último mês) em vez de acumular meses.

Onde o método detecta pouco. Erros de negócio de baixa intensidade (5% de 4xx generalizado) raramente são detectados, porque vários recursos têm taxas de 4xx naturais altas e variáveis. Recursos com picos reais frequentes (4xx em A05, A06, A07 e A08) recebem limites altos e só mostram desvios grandes; no A06, com limites de 4xx e 5xx muito altos e minutos sem dados, a sensibilidade foi de 26%. Nesses casos, o próprio limite é uma informação útil: ele diz ao operador que aquele indicador já é instável no recurso.

6 AMEAÇAS À VALIDADE

Falhas sintéticas. O desempenho mede a capacidade de detectar *os motivos injetados*. As intensidades variadas, os quatro atrasos e o grande número de cenários reduzem, mas não eliminam, esse viés.

Decisões tomadas ao longo do estudo. O ponto de operação (limite no percentil 99), a intensidade de latência ×10 e a limitação dos indicadores aos percentis 1 e 99 no k-means foram definidos em versões anteriores do estudo, com outros recursos e períodos, e mantidos sem alteração nesta versão. O histórico principal (3 meses) foi fixado antes de observar os resultados, e o resultado desfavorável a ele é relatado. O critério de sensibilidade foi atingido por margem estreita (70,6% contra 70%), e o seu intervalo de confiança (68,8% a 72,2%) inclui valores abaixo da meta.

Seleção dos recursos. Foram usados apenas recursos com dados em todos os dias do período, o que favorece recursos estáveis e de alto volume. Os quatro descartados (21% do volume) poderiam ter comportamento diferente. Dois recursos incluídos (A05 e A06) têm minutos sem dados, e 69 incidentes simulados caíram nesses intervalos e foram excluídos.

Controles e anomalias reais. As consultas de controle usam dados reais sem injeção, que podem conter anomalias reais (como a do A12), contadas como falso Residual. A especificidade é, portanto, uma estimativa conservadora.

Latência aproximada. O p95 é calculado sobre as médias por minuto e por cliente, e não sobre requisições; a cauda real tende a ser maior. Uma latência 10 vezes maior poderia, na prática, esbarrar no *timeout* do gateway e virar erro 504, o que a injeção não simula.

Período e generalização. O teste cobre 20 dias de setembro, com um feriado (07/09); os feriados considerados foram 04/06 (Corpus Christi, tratado como não útil) e 07/09. Os resultados vêm de uma organização e de 14 recursos. A base não pode ser compartilhada; o código dos notebooks é independente dos dados.

7 CONSIDERAÇÕES FINAIS

Este trabalho mostrou que Access Logs agregados por minuto, sem *traces* nem logs de aplicação, permitem caracterizar os regimes normais de cada recurso de API e informar, no instante em que um incidente é aberto, se o recurso está em regime normal e, se não, qual indicador foi impactado (erros de negócio, erros de sistema ou latência) e desde quando. O método usa técnicas simples (mediana, MAD, percentis, validação cruzada e uma busca retroativa), não exige rótulos e produz uma explicação que um agente ou operador pode usar diretamente.

Em 14 recursos de alto volume, a informação foi confiável e útil: 97,3% de especificidade, 63% de sensibilidade (71% nas degradações médias e altas; até 99% para erros de sistema e 90% para latência de 10 vezes), 98,2% de acerto no indicador e 94,8% de acerto na zona de início. Os cinco critérios de sucesso foram atendidos. O ponto fraco são os erros de negócio de baixa intensidade em recursos com muitos 4xx naturais. O histórico recente (1 mês) mostrou-se melhor que o longo (3 meses), o que recomenda retreino frequente.

Como trabalhos futuros, destacam-se: (i) validar o método com incidentes reais, começando pelo evento de latência observado no A12, e com a avaliação de operadores; (ii) adotar o histórico de 1 mês com retreino mensal e avaliar janelas deslizantes ponderadas; (iii) melhorar a sensibilidade a erros de negócio e à latência com percentis por requisição; (iv) avaliar recursos de menor volume e outras APIs; e (v) integrar a consulta como ferramenta de um agente de apoio a incidentes.

REFERÊNCIAS

Julien Audibert, Pietro Michiardi, Frédéric Guyard, Sébastien Marti, and Maria A. Zuluaga. 2020. USAD: UnSupervised Anomaly Detection on Multivariate Time Series. In *Proceedings of the 26th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining (KDD '20)*. ACM, New York.

Pete Chapman, Julian Clinton, Randy Kerber, Thomas Khabaza, Thomas Reinartz, Colin Shearer, and Rüdiger Wirth. 2000. *CRISP-DM 1.0: Step-by-Step Data Mining Guide*. Technical Report. SPSS.

Min Du, Feifei Li, Guineng Zheng, and Vivek Srikumar. 2017. DeepLog: Anomaly Detection and Diagnosis from System Logs through Deep Learning. In *Proceedings of the 2017 ACM SIGSAC Conference on Computer and Communications Security (CCS '17)*. ACM, New York, 1285–1298.

Olive Jean Dunn. 1961. Multiple Comparisons among Means. *J. Amer. Statist. Assoc.* 56, 293 (1961), 52–64.

William H. Kruskal and W. Allen Wallis. 1952. Use of Ranks in One-Criterion Variance Analysis. *J. Amer. Statist. Assoc.* 47, 260 (1952), 583–621.

Christophe Leys, Christophe Ley, Olivier Klein, Philippe Bernard, and Laurent Licata. 2013. Detecting Outliers: Do Not Use Standard Deviation Around the Mean, Use Absolute Deviation Around the Median. *Journal of Experimental Social Psychology* 49, 4 (2013), 764–766.

Stuart Lloyd. 1982. Least Squares Quantization in PCM. *IEEE Transactions on Information Theory* 28, 2 (1982), 129–137.

Yu Luo et al. 2025. OpsAgent: An Evolving Multi-Agent System for Incident Management in Microservices. arXiv:2510.24145. Acesso em: 18 maio 2026.

Quinn McNemar. 1947. Note on the Sampling Error of the Difference between Correlated Proportions or Percentages. *Psychometrika* 12, 2 (1947), 153–157.

Weibin Meng, Ying Liu, Yichen Zhu, Shenglin Zhang, Dan Pei, Yuqing Liu, Yihao Chen, Ruizhi Zhang, Shimin Tao, Pei Sun, and Rong Zhou. 2019. LogAnomaly: Unsupervised Detection of Sequential and Quantitative Anomalies in Unstructured Logs. In *Proceedings of the Twenty-Eighth International Joint Conference on Artificial Intelligence (IJCAI-19)*. IJCAI Organization, Macao, 4739–4745. https://doi.org/10.24963/ijcai.2019/658

Fabian Pedregosa, Gaël Varoquaux, Alexandre Gramfort, Vincent Michel, Bertrand Thirion, Olivier Grisel, Mathieu Blondel, Peter Prettenhofer, Ron Weiss, Vincent Dubourg, Jake Vanderplas, Alexandre Passos, David Cournapeau, Matthieu Brucher, Matthieu Perrot, and Édouard Duchesnay. 2011. Scikit-learn: Machine Learning in Python. *Journal of Machine Learning Research* 12 (2011), 2825–2830.

Peter J. Rousseeuw. 1987. Silhouettes: A Graphical Aid to the Interpretation and Validation of Cluster Analysis. *J. Comput. Appl. Math.* 20 (1987), 53–65.

Alban Siffer, Pierre-Alain Fouque, Alexandre Termier, and Christine Largouet. 2017. Anomaly Detection in Streams with Extreme Value Theory. In *Proceedings of the 23rd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining (KDD '17)*. ACM, New York, 1067–1075.

Gagan Somashekar, Anurag Dutt, Mainak Adak, Tania Lorido Botran, and Anshul Gandhi. 2024. GAMMA: Graph Neural Network-Based Multi-Bottleneck Localization for Microservices Applications. In *Proceedings of the ACM Web Conference 2024 (WWW '24)*. ACM, New York, 3085–3095.

Yuqing Wang, Mika V. Mäntylä, Serge Demeyer, Mutlu Beyazit, Joanna Kisaakye, and Jesse Nyyssölä. 2025. Cross-System Categorization of Abnormal Traces in Microservice-Based Systems via Meta-Learning. *Proceedings of the ACM on Software Engineering* 2, FSE (2025). Artigo FSE027.

Edwin B. Wilson. 1927. Probable Inference, the Law of Succession, and Statistical Inference. *J. Amer. Statist. Assoc.* 22, 158 (1927), 209–212.

Rüdiger Wirth and Jochen Hipp. 2000. CRISP-DM: Towards a Standard Process Model for Data Mining. In *Proceedings of the 4th International Conference on the Practical Applications of Knowledge Discovery and Data Mining*. 29–39.

Zhaoyang Yu et al. 2025. Triangle: Empowering Incident Triage with Multi-Agent. In *Proceedings of the 40th IEEE/ACM International Conference on Automated Software Engineering (ASE 2025)*. IEEE/ACM. Disponível em: https://www.microsoft.com/en-us/research/wp-content/uploads/2025/02/TRIANGLE_ASE25.pdf. Acesso em: 18 maio 2026.

Chenxi Zhang, Xin Peng, Chaofeng Sha, Ke Zhang, Zhenqing Fu, Xiya Wu, Qingwei Lin, and Dongmei Zhang. 2022. DeepTraLog: Trace-Log Combined Microservice Anomaly Detection through Graph-Based Deep Learning. In *Proceedings of the 44th International Conference on Software Engineering (ICSE '22)*. ACM, New York, 623–634.

Wei Zhang et al. 2025. Intelligent Site Reliability Engineering: A Multi-Agent LLM Framework for Automated Incident Analysis and Root Cause Determination. https://www.researchgate.net/publication/399119176. Acesso em: 10 maio 2026.